TP555 - AI/ML
Lista de Exercícios #3
Regressão para Modelos Não-Lineares

1. Exercício sobre regressão não-linear. Dada a seguinte função não-linear

$$y = a_0 x^{a_1}$$

Como você poderia linearizar essa função (lembre-se que a nova função é linear em relação aos pesos e não em relação ao atributo)? Qual é a função hipótese que você poderia usar para encontrar os pesos da função geradora? Imagine que você só tem acesso aos vetores x e y. Supondo que $a_0 = 1,4$ e $a_1 = 3,0$ e x é igual a um vetor com $M = 1000$ amostras retiradas de uma distribuição Uniforme no intervalo $[0,0, 10,0)$, faça o seguinte:

   a) Plote o gráfico da função não-linear (i.e., x versus y).

   b) Linearize a função não-linear.

   c) Plote o gráfico da função linearizada, i.e., x versus y.

   d) Utilizando a função hipótese que lineariza a função-geradora,

      - Plote a superfície de erro.
      - Encontre os valores ótimos dos pesos da função hipótese utilizando a equação normal.
      - Encontre os pesos da função hipótese utilizando o algoritmo do gradiente descendente em batelada com **critério de parada** definido como sendo quando a **diferença absoluta** entre o erro da iteração atual e a anterior caia abaixo de 0,00001 ou que o número máximo de épocas tenha sido atingido. Faça o número máximo de épocas igual a 1000. (**OBS.:** não se esqueça de encontrar o melhor valor para o passo de aprendizagem).
      - Plote a superfície de contorno mostrando o histórico de atualização dos pesos e seus valores ótimos.
      - Plote o gráfico de erro versus número de épocas.

   e) Quais os valores dos pesos encontrados pelo algoritmo do gradiente descendente em batelada?

2. Suponha que você esteja usando regressão polinomial. Você plota as **curvas de aprendizado** e percebe que há uma grande diferença entre o erro de treinamento e o erro de validação. O que está acontecendo? Quais são as três maneiras de resolver isso?

   OBS.: Curvas de aprendizado: são gráficos mostrando o desempenho do modelo no conjunto de treinamento e no conjunto de validação em função do tamanho do conjunto de treinamento (ou da iteração do treinamento).

3. Exercício de comparação entre as regressões Ridge e LASSO. Dada a seguinte versão ruidosa da função objetivo

$$y_{\text{noisy}} = 2 + x + 0,5x^2 + n,$$

onde x é um vetor coluna com $M = 100$ elementos retirados de uma distribuição aleatória uniformemente distribuída variando entre -3 e 3 e n é o vetor ruído com M elementos retirados de uma distribuição aleatória Gaussiana com média 0 e variância unitária. Utilize um polinômio de ordem 90, padronização de atributos (ou seja, remoção da média e divisão pelo desvio padrão) e regressão LASSO (utilize a biblioteca SciKit-Learn) com λ variando entre 10^{-10} e 1 (utilize `np.linspace`$(10^{-10}, 1, 1000)$). Utilizando a função `train_test_split`, divida os exemplos em um conjunto de treinamento e outro de validação com proporção 70% e 30%, respectivamente. Faça o seguinte:

   a) Plote um gráfico mostrando a função objetivo e sua versão ruidosa.

   b) Crie um loop para testar cada um dos 1000 valores de λ. Para cada novo valor de λ, treine o modelo, execute a predição e calcule os erros de treinamento e validação.

   c) Para cada iteração do loop, armazene os valores do erro de treinamento e validação em um vetor.

   d) Para cada iteração do loop, verifique se o valor do erro de validação atual é menor do que o erro de validação mínimo. Se sim, armazene o valor de λ e o modelo utilizado para aquela iteração. (**Dica:** inicialize a variável contendo o erro de validação mínimo como: `minimum_val_error = float(“inf")`).

   e) Plote um gráfico mostrando os erros de treinamento e validação versus todos os valores de λ, ou seja, os 1000 valores de λ.

   f) Baseado no menor valor do erro de validação, qual é o valor ótimo para λ?

   g) Dado que você armazenou o modelo que obteve o menor erro de validação, utilize-o para criar um gráfico que mostre a função hipótese (ou seja, o mapeamento do atributos de entrada, x, nos valores de saída, y, através do modelo treinado) e a função objetivo e sua versão ruidosa.

   h) Imprima os valores dos pesos obtidos durante o treinamento do modelo que obteve o menor erro de validação (Dica: use o atributo `named_steps` da classe `Pipeline` para acessar os objetos que compõem o pipeline: documentação do Pipeline).

   i) Repita os passos anteriores para a regressão de Ridge.

   j) O que você percebe com relação aos pesos obtidos com as regressões Ridge e LASSO?

(Dica: Não se esqueça que os parâmetros do escalonamento de atributos, ou seja, média e devio padrão, são encontrados utilizando-se o conjunto de treinamento. Os parâmetros encontrados são utilizados para escalonar o conjunto de validação).

(**Dica:** Na instanciação da classe Lasso, configure a tolerância para 1, i.e., tol=1.)

(**Dica:** A documentação do regressor LASSO pode ser acessada através deste link: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html?highlight=lasso#sklearn.linear_model.Lasso)

(**Dica:** utilize a classe clone para criar uma cópia do modelo que atingiu erro de validação menor do que o valor mínimo atual.

https://scikit-learn.org/stable/modules/generated/sklearn.base.clone.html)

4. Exercício sobre Early stopping. Dada a seguinte versão ruidosa da função objetivo

$$y_{\text{noisy}} = 2 + x + 0,5x^2 + x^3 + n,$$

onde x é um vetor coluna com $M = 100$ elementos retirados de uma distribuição aleatória uniformemente distribuída variando entre -3 e 3 e n é o vetor ruído com M elementos retirados de uma distribuição aleatória Gaussiana com média 0 e variância unitária. Utilize um polinômio de ordem 30 como função hipótese, padronização de atributos (ou seja, remoção da média e divisão pelo desvio padrão) e o algoritmo do gradiente descendente em batelada. Utilizando a função `train_test_split`, divida os exemplos em um conjunto de treinamento e outro de validação com proporção 70% e 30%, respectivamente. Faça o seguinte:

   a) Plote um gráfico mostrando a função objetivo e sua versão ruidosa.

   b) Encontre, manualmente, o melhor valor para o passo de aprendizagem.

   c) Execute o treinamento por 1000 épocas.

   d) Para cada época, armazene em um vetor os valores do erro de treinamento e validação.

   e) Para cada época, verifique se o valor do erro de validação atual é menor do que o erro de validação mínimo. Se sim, armazene o modelo utilizado para aquela época, ou seja, os valores dos pesos, e o valor do erro de validação para aquela época. (**Dica:** inicialize a variável contendo o erro de validação mínimo como: `minimum_val_error = float(“inf")`).

   f) Plote um gráfico mostrando os erros de treinamento e validação versus o número de épocas.

   g) Dado que você armazenou o modelo que obteve o menor erro de validação, utilize-o para criar um gráfico que mostre a função hipótese (ou seja, o mapeamento dos atributos de entrada, x, nos valores de saída, y, através do modelo treinado) e a função objetivo e sua versão ruidosa.

5. Exercício que utiliza validação cruzada. Usando o arquivo covid19.csv, onde a primeira coluna são os valores de x (i.e., atributo) representando o número de dias desde o primeiro caso confirmado de COVID-19 e a segunda coluna são os valores de y (i.e., objetivo ou rótulo), representando o número de casos de COVID-19 ativos. Leia o conteúdo do arquivo com os seguintes comandos:

```
import pandas as pd
import matplotlib.pyplot as plt
df = pd.read_csv('./covid19.csv', header=None)
x = df[0].to_numpy()
y = df[1].to_numpy()
x = x.reshape(len(x), 1)
y = y.reshape(len(y), 1)
fig = plt.figure(figsize=(10, 10))
plt.plot(x, y, 'b.')
```

Em seguida, faça o seguinte:

a) Plote os valores do arquivo, i.e., um gráfico mostrando os dias desde o primeiro caso versus o número de casos ativos.

b) Encontre uma aproximação polinomial que represente bem os dados do arquivo. Para encontrar a melhor aproximação, utilize os seguintes métodos: validação cruzada holdout (com 80% do conjunto original para treinamento e 20% para validação), validação cruzada k-fold (com $k = 10$ folds), validação cruzada leave-p-out (com $p = 1$) e curvas de aprendizado. Analise polinômios com ordem variando de 1 até 12.

c) De posse da melhor ordem de polinômio que aproxima o modelo gerador, treine o modelo com todos os dados do arquivo csv. Utilize padronização de atributos com a classe `StandardScaler` da biblioteca SciKit-Learn.

d) De posse do modelo treinado, crie um vetor x variando de 1 a 70 com incrementos de 1 em 1, i.e., número de dias desde o primeiro caso registrado até 70 dias depois, e faça a predição do número de casos ativos até 70 dias após o primeiro caso registrado.

e) Sabendo que o número total de leitos de UTI no Brasil é de 40600 (aqui vamos supor que nenhum leito está ocupado no momento), preveja em quantos dias desde o início do primeiro caso registrado no Brasil (26-02-2020) o número de leitos total seria atingido.

6. Neste exercício você vai utilizar o arquivo reg_poli.csv onde a primeira coluna são os valores de x (atributo) e a segunda de y (objetivo ou rótulo). O arquivo contém a versão ruidosa da função original, ou seja o modelo gerador ao qual ruído é adicionado. Após, leia o conteúdo do arquivo, ou seja, os vetores $\mathbf{x}$ e $\mathbf{y}$, com os seguintes comandos:

```
import pandas as pd
import matplotlib.pyplot as plt
df = pd.read_csv('./reg_poli.csv', header=None)
x = df[0].to_numpy()
y = df[1].to_numpy()
x = x.reshape(len(x), 1)
y = y.reshape(len(y), 1)
fig = plt.figure(figsize=(10, 10))
plt.plot(x, y, 'b.')
```

Em seguida:

a) Apresente o gráfico de x versus y, mostrando os **pontos** amostrados do modelo gerador.

b) Encontre uma aproximação polinomial que represente bem os dados do arquivo. Para encontrar a melhor aproximação, utilize os seguintes métodos: validação cruzada holdout (com 70% do conjunto original para treinamento e 30% para validação), validação cruzada k-fold (com $k = 10$ folds), validação cruzada leave-p-out (com $p = 1$) e curvas de aprendizado. Analise polinômios com ordem variando de 1 até 12.

c) De posse da melhor ordem de polinômio que aproxima os dados do arquivo csv, treine o modelo com todos os dados do arquivo csv. Utilize padronização de atributos com a classe `StandardScaler` da biblioteca SciKit-Learn.

d) Plote um gráfico que mostre os pontos ruidosos do arquivo `reg_poli.csv` e os valores encontrados com o modelo para os valores de x vindos do arquivo csv, ou seja, use o modelo para "prever" os valores de y com os valores de x vindos do arquivo.

7. Neste exercício você irá utilizar regressão LASSO para encontrar a ordem de uma função hipótese polinomial que melhor se ajuste aos dados de treinamento fornecidos. Utilize os arquivos training_lasso.csv e validation_lasso.csv para treinar e validar seu modelo, respectivamente.

   a) Plote as amostras de ambos os arquivos.

   b) Utilize uma função polinomial de ordem igual a 40.

   c) Treine um modelo de regressão linear (sem regularização) com os dados de treinamento (utilize padronização para escalonar os atributos).

   d) De posse do modelo treinado, faça a predição com os dados de treinamento e validação e em seguida plote um gráfico comparando os valores obtidos com a predição e os valores dos arquivos de treinamento e validação.

      - Observando o gráfico, o que você pode concluir que está ocorrendo?

   e) Treine um modelo de regressão linear com regularização LASSO (use a classe `Lasso` da biblioteca SciKit-Learn) com os dados de treinamento (utilize padronização para escalonar os atributos). Crie um laço de repetição para que você treine modelos de regressão LASSO com diferentes valores de λ, variando de 10^{-10} até 100. Armazene o valor do erro quadrático médio (MSE) para cada valor de λ.

   f) Plote um gráfico mostrando o MSE versus o valor de λ.

   g) Encontre o valor de λ que resulta no menor erro de validação, treine um novo modelo de regressão LASSO com este valor, realize a predição com os dados de treinamento e validação e em seguida plote um gráfico comparando os resultados obtidos com a predição e os valores dos arquivos de treinamento e validação.

      - Observando o gráfico, você ainda observa o mesmo fenômeno que ocorria antes, quando utilizamos apenas a regressão linear sem regularização?

h) De posse do modelo de regressão LASSO treinado com o valor de λ que resulta no menor erro de validação, crie um laço de repetição para variar o número de pesos considerados para a predição, varie de 2 (polinômio de ordem 1) até 41 (polinômio de ordem 40). Armazene o MSE de validação para cada uma das iterações.

i) Plote um gráfico mostrando a variação do MSE de validação quando o número de pesos considerados varia de 2 a 41.

j) De posse dos valores de MSE do item anterior, encontre a quantidade de pesos que resulta no menor MSE. Usando apenas a quantidade de pesos que resulta no menor MSE, realize a predição com os dados de treinamento e validação. Em seguida, plote um gráfico comparando os resultados obtidos com a predição e os valores dos arquivos de treinamento e validação. (**Dica:** sempre padronize os atributos)

- Observando o gráfico, pode-se dizer que o resultado é similar ao obtido com o modelo de regressão LASSO de ordem 40 da letra (g)?
- Compare com outras quantidades de pesos, por exemplo, 2, 3, e 5.

8. Exercício sobre early stopping. Utilizando a seguinte função geradora ruidosa

$$y = a_0 + a_1 x + w,$$

onde $a_0 = 1.0$, $a_1 = 2.0$, x é um vetor coluna com $M \times 1$ elementos retirados de uma distribuição uniformemente distribuída entre o intervalo [-1,0, 1,0), w é o ruído adicionado à função geradora e é um vetor coluna com Mx1 elementos retirados de uma distribuição Gaussiana com média zero e variância igual a 0,09 e M = 50. Gere agora um conjunto de validação, utilizando Mtest = 50 valores **linearmente espaçados entre [-1,0, 1,0)** ao invés de valores retirados de uma distribuição uniforme, conforme usamos para gerar os dados de treinamento. De posse dos 2 conjuntos (treinamento e validação), faça o seguinte:

(a) Plote em um gráfico os dados originais e os valores dos conjuntos de treinamento e validação.

(b) Treine um modelo de Regressão Polinomial de ordem igual a 40 (use a classe **LinearRegression** da biblioteca SciKit-Learn ou implemente a forma fechada).

(c) Plote em um gráfico os dados originais, os valores dos conjuntos de treinamento e validação e os valores de predição obtidos com o modelo treinado quando se utiliza os conjuntos de treinamento e validação como entrada do modelo.

(d) Após analisar o gráfico da letra (c), o que você conclui? O que está ocorrendo?

(e) Agora, treine um modelo **polinomial** de ordem igual a 40 utilizando o **gradiente descendente em batelada com early stopping**. Configure o número máximo de épocas para 100000 e não utilize critério de parada, deixe o algoritmo treinar as 100000 épocas e sempre armazene os pesos que resultaram no menor erro de validação. (**OBS.:** Não se esqueça de encontrar o melhor valor para o passo de aprendizagem).

(f) Após o treinamento, plote um gráfico mostrando o número de épocas versus os erros de treinamento e validação (MSE).

(g) Após observar o gráfico, o que você conclui? O que está ocorrendo durante o treinamento iterativo do modelo?

(h) Plote em um gráfico os dados originais, os valores dos conjuntos de treinamento e validação e os valores de predição obtidos com o modelo treinado iterativamente quando se utiliza os conjuntos de treinamento e validação como entrada do modelo.

(i) Após analisar o gráfico da letra (h), o que você conclui? O que está ocorrendo? Qual a diferença entre este gráfico e o obtido na letra (c).

(j) Utilizando o último valor dos pesos, ou seja, os pesos obtidos após a época de número 100000, plote em um gráfico os dados originais, os valores dos conjuntos de treinamento e validação e os valores de predição obtidos com o modelo treinado iterativamente quando se utiliza os conjuntos de treinamento e validação como entrada do modelo.

(k) Após analisar o gráfico da letra (j), o que você conclui? O que está ocorrendo? Qual a diferença entre este gráfico e o obtido na letra (h).

9. Proponha um exercício sobre Ridge regression. Crie um enunciado para este exercício e apresente a sua solução.