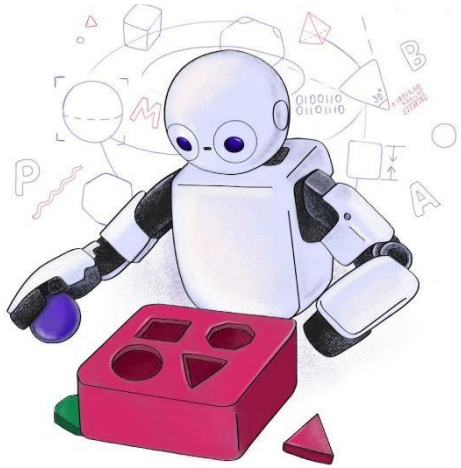
TP555 - Inteligência Artificial e Machine Learning: *Árvores de Decisão*

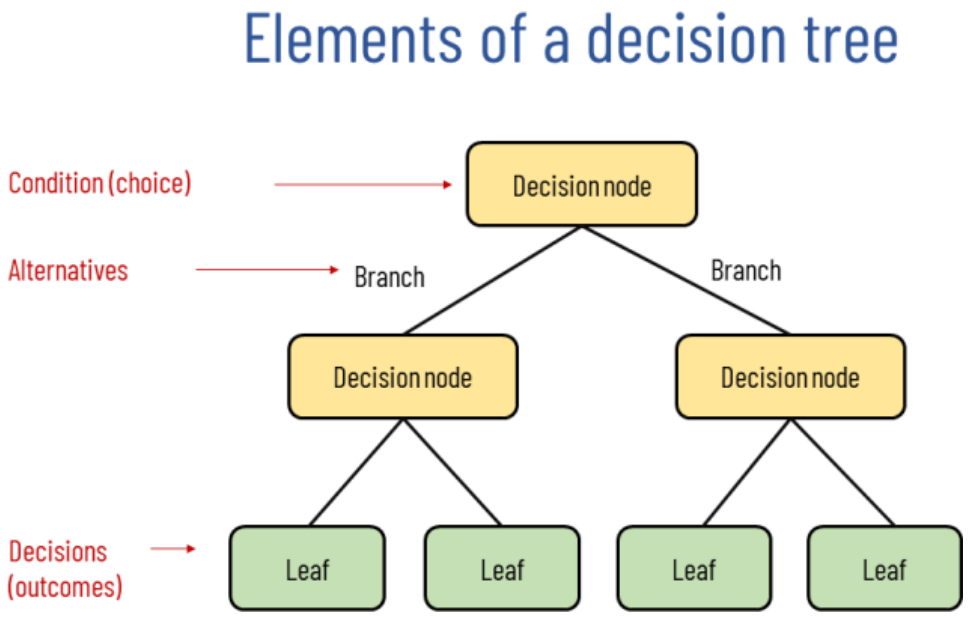


Esse material foi desenvolvido e gentilmente cedido pelo Prof. Dr. Felipe Augusto Pereira de Figueiredo, do Inatel.(felipe.figueiredo@inatel.br)

Inatel

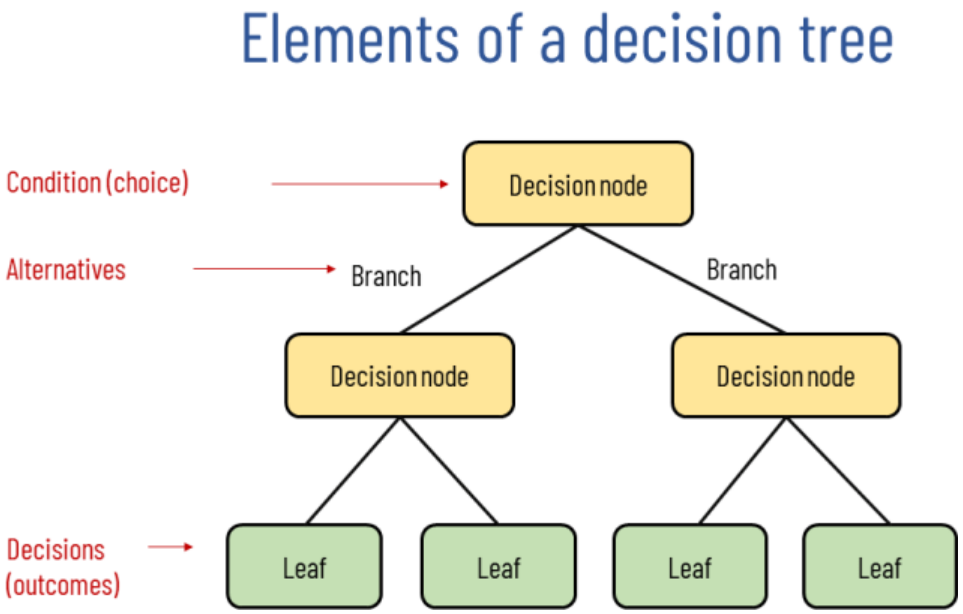
Prof. Dr. Luiz Augusto Melo Pereira
luiz.melo@inatel.br

Árvores de decisão



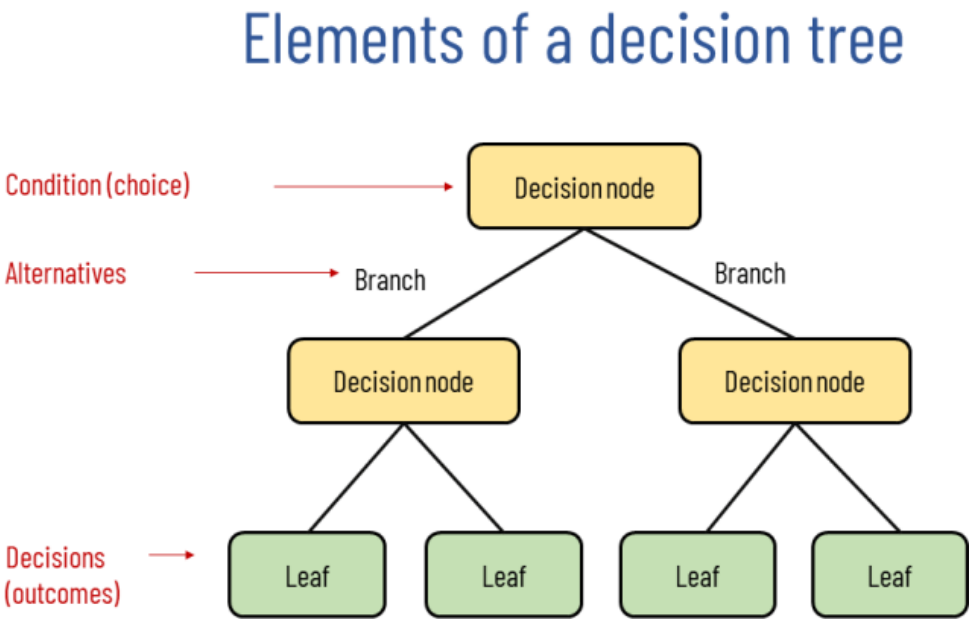
- Assim como o k-NN, uma ***árvore de decisão*** (do inglês, ***decision trees***), é um algoritmo de ***aprendizado supervisionado não-paramétrico*** e ***não-linear*** que pode ser utilizado tanto para ***classificação*** quanto para ***regressão***.
- Podem ser interpretadas como uma ***estrutura de controle de fluxo***.

Árvores de decisão



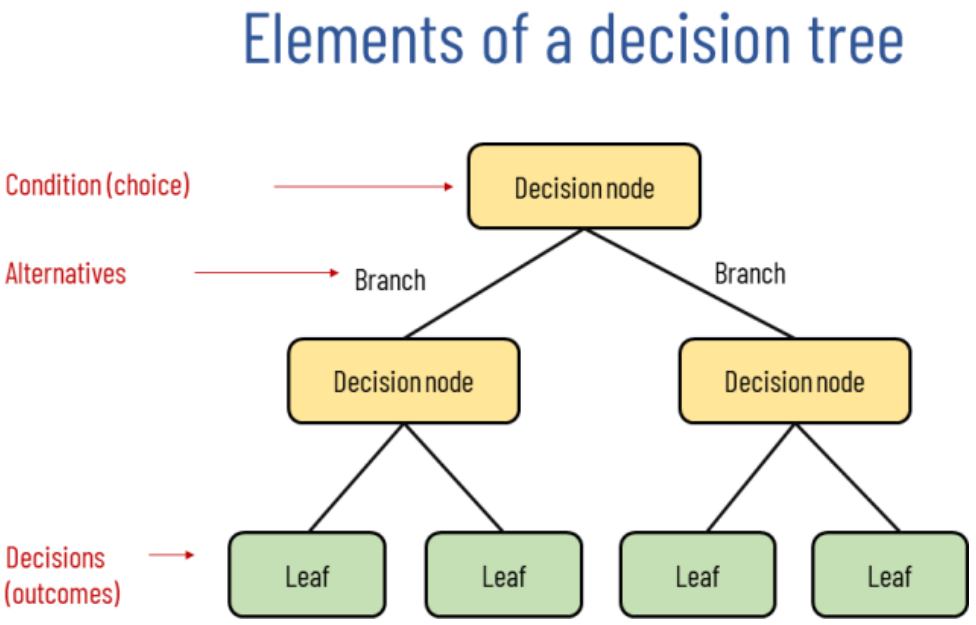
- ***Não-paramétrico***: elas ***não fazem suposições sobre a distribuição*** dos dados ou ***sobre a forma da função*** que estão tentando aprender.
- ***Não definem um número fixo de parâmetros*** como em modelos lineares, que têm um número fixo de pesos.
- Em vez de definir um número fixo de parâmetros, as ***árvores de decisão ajustam sua complexidade à medida que crescem***, dependendo da estrutura dos dados.

Árvores de decisão



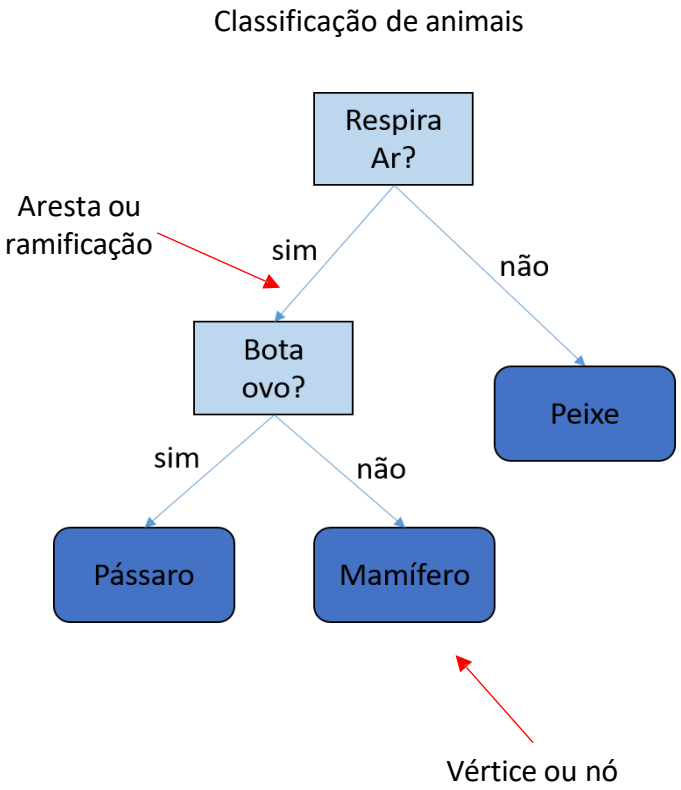
- Ou seja, os ***parâmetros são criados durante o treinamento*** ***para explicar os dados***.
- O ***modelo é construído apenas com base nos dados observados***
- O ***tamanho da árvore***, i.e., o número de parâmetros, ***tende a crescer com a base de dados***.

Árvores de decisão



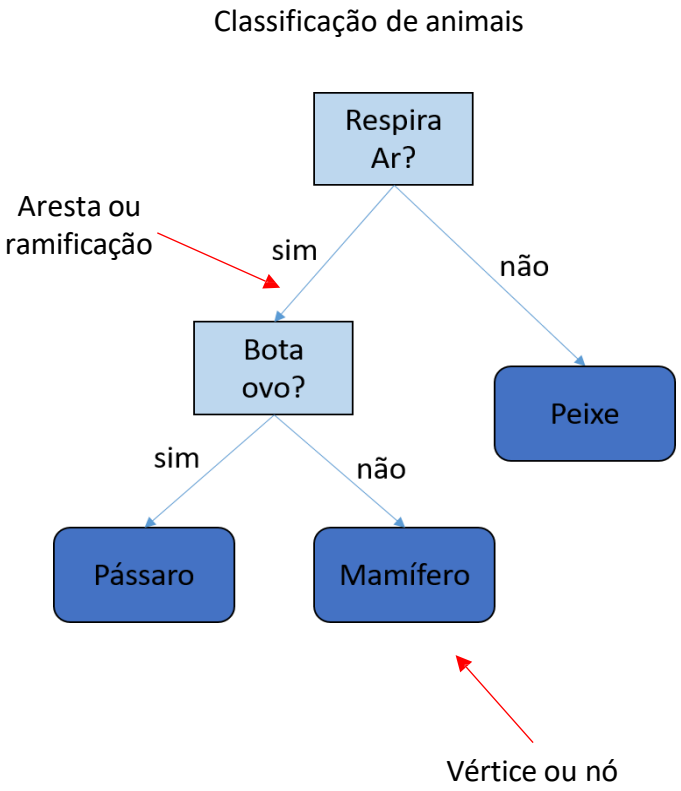
- Esse modelo é ***não-paramétrico***, não porque não tenha nenhum parâmetro, mas porque o ***número de parâmetros não é determinado antes do treinamento***, de modo que a árvore é livre para se adaptar aos dados de treinamento.
- ***Não-linear***: funções hipótese e discriminante são ***funções não-lineares***, i.e., os dados não são aproximados ou separados por um ***hiperplano***.

Árvores de decisão



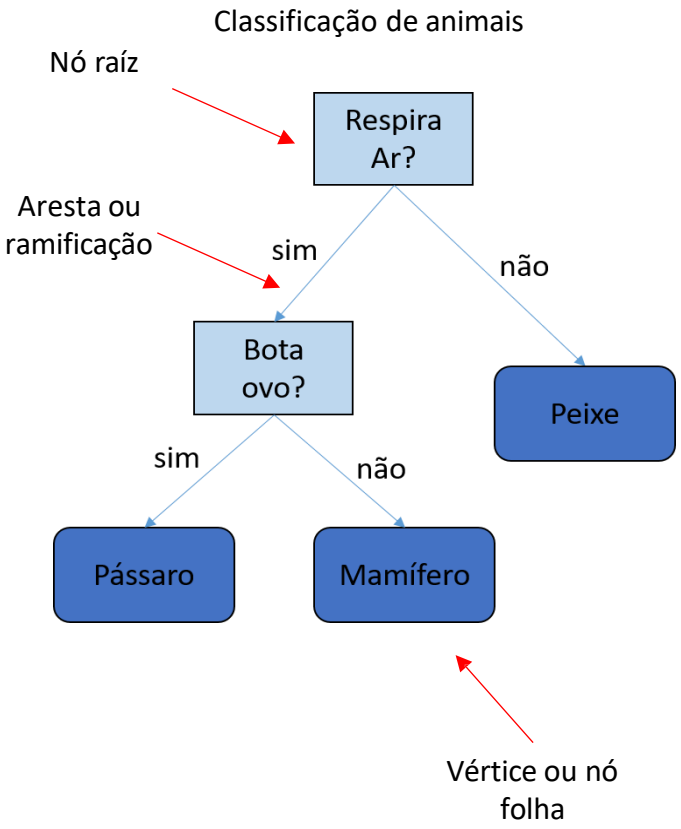
- O objetivo é criar um modelo que realize predições aprendendo ***regras simples de decisão inferidas*** a partir dos ***atributos do conjunto de treinamento***.
- As ***árvores de decisão*** são os componentes fundamentais das ***florestas aleatórias*** (do inglês, ***random forests***) que estão entre os ***algoritmos mais poderosos de aprendizado de máquina*** disponíveis atualmente.

Árvores de decisão



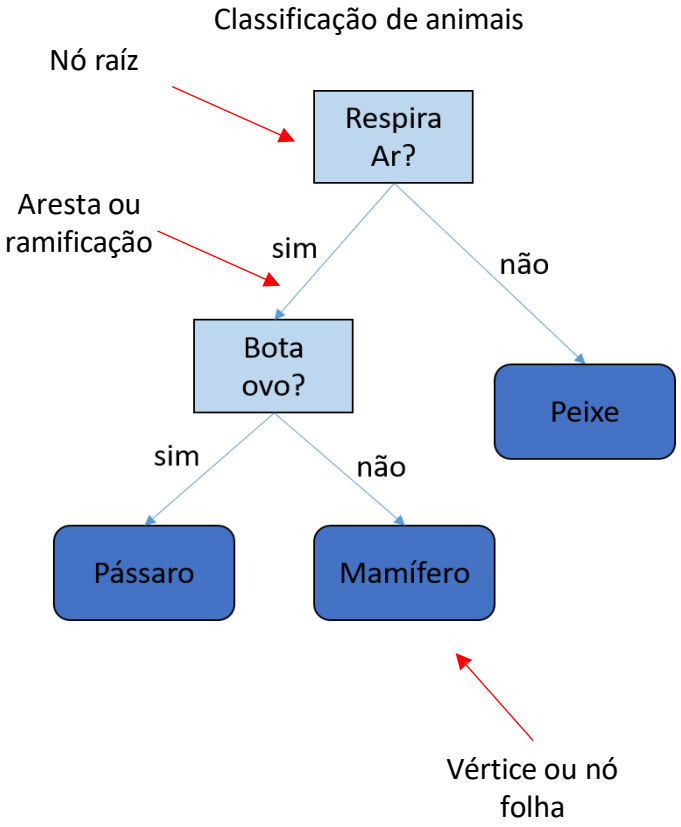
- Formalmente, uma árvore é um ***grafo não-direcionado*** no qual dois ***vértices*** quaisquer se conectam por um único caminho (ou seja, um ***grafo acíclico não-direcionado***) [Wikipedia, 2019].
  - Um ciclo é um caminho em que o primeiro e o último vértice coincidem.
- Por exemplo, o vértice “Pássaro” só se conecta com o vértice “Mamífero” através do vértice “Bota ovo?” e não existe um caminho que termine no mesmo vértice de início.

Árvores de decisão



- A árvore possui um ***nó raiz***, do qual ***parte o processo de decisão***.
- Nesse processo, ***valores distintos dos atributos geram arestas*** (i.e., ***ramificações***) e, quando se chega a um ***nó folha***, ocorre uma ***atribuição de uma classe ou valor***.

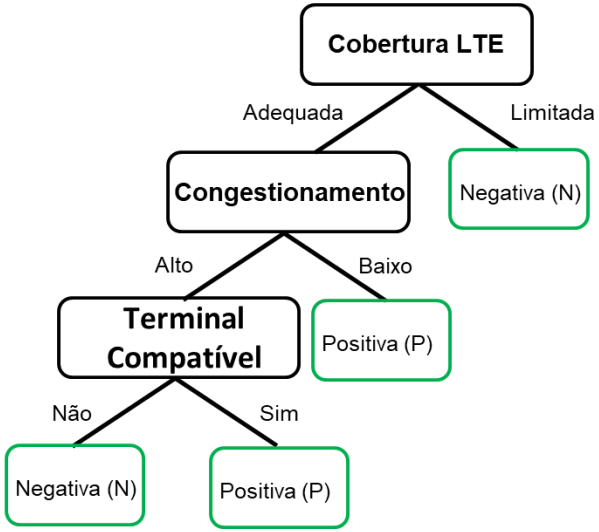
Árvores de decisão



- ***Árvores de decisão*** são modelos de ***caixa branca***, ou seja, é possível entender e ***explicar facilmente como o modelo realiza a classificação ou regressão*** baseando-se nos atributos.
- Elas são o oposto dos modelos de ***caixa preta***, onde os resultados são difíceis de interpretar e ***não é fácil entender como os diferentes atributos interagem entre si para gerar a saída*** (e.g., redes neurais artificiais).

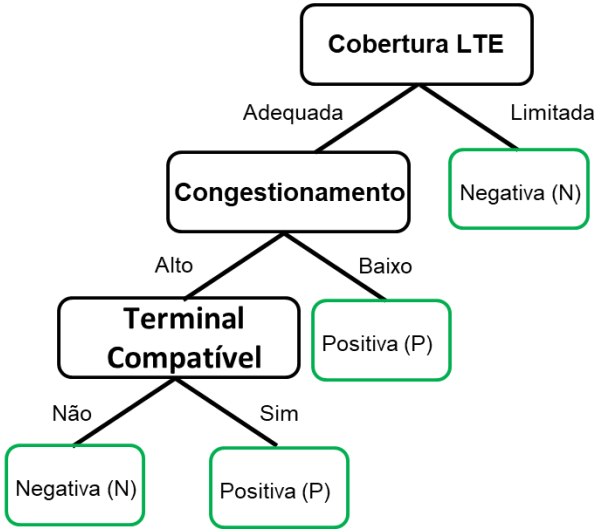
Árvores de decisão

- A figura abaixo mostra uma árvore de decisão criada a partir de informações se uma chamada será completada ou não dependendo dos valores dos atributos ***Cobertura LTE***, ***Congestionamento*** e ***Terminal Compatível***.
- Cada ***nó da árvore atua como um caso de teste*** para algum atributo, e cada extremidade, ou seja, uma terminação ou folha, corresponde a uma classe.



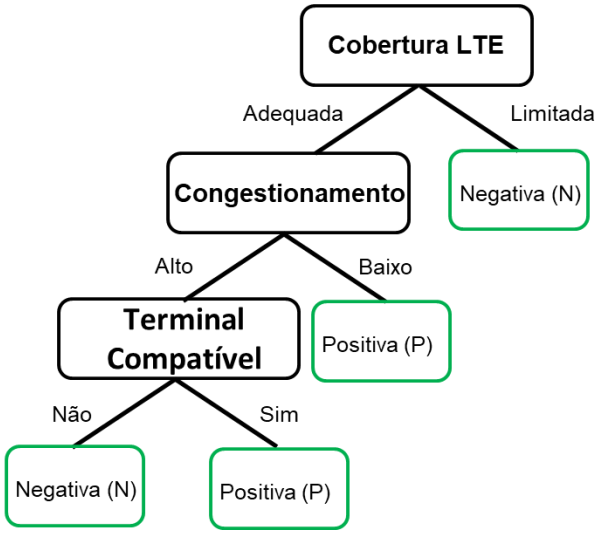
Árvores de decisão

- Na figura, cada atributo leva a uma ramificação até que se atinja um nó folha, onde decide-se sobre completar a chamada ou não.
- O ***uso da árvore para classificar padrões é direto***, mas é preciso responder uma questão crucial: ***como induzir uma árvore de decisão a partir dos dados de treinamento***?



O processo de indução de uma árvore de decisão

- Uma primeira abordagem para induzir uma árvore poderia ser ***construir, de maneira exaustiva***, todas as árvores ***capazes de resolver o problema*** da classificação ou regressão e ***selecionar a mais simples*** (menos complexa) utilizando a ***regra da Navalha de Occam***.
- Entretanto, essa abordagem pode ser computacionalmente muito custosa.

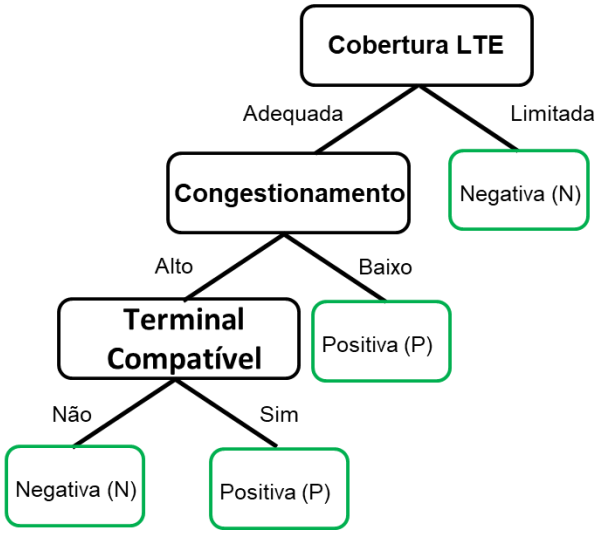


O processo de indução de uma árvore de decisão

- Encontrar uma árvore de decisão ótima é um problema ***tempo polinomial não-determinístico completo*** (NP-completo).
- São problemas:
  - Cuja solução pode ser verificada em tempo polinomial.
    - Um algoritmo roda em tempo polinomial se o tempo necessário para resolver um problema de tamanho n é limitado por uma função polinomial de n.
    - Por exemplo, a inversa de uma matriz $n \times n$ pode ser calculada em n^3.
  - Não se sabe se existe um algoritmo eficiente (polinomial) para **resolver** o problema.
- Exemplos incluem problemas clássicos como da Satisfatibilidade Booleana, Caixeiro Viajante e o Caminho Hamiltoniano.

O processo de indução de uma árvore de decisão

- Como a indução de árvores são problemas NP-completos, em geral, usa-se ***abordagens heurísticas*** para induzir árvores de decisão.
- Dentre os mais conhecidos podemos citar: **ID3**, C4.5, C5.0 e **CART (scikit-learn)**.



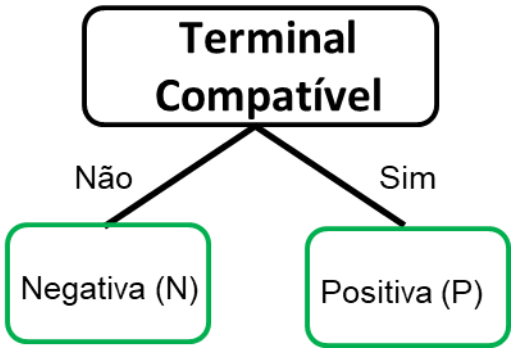
O processo de indução de uma árvore de decisão

- Um dos métodos ***heurísticos*** de indução de árvores de decisão mais utilizados é o ***ID3*** (do inglês, ***Iterative Dichotomiser 3***).
  - ***Heurística:*** estratégia prática para encontrar uma solução rápida e aproximada.
  - ***Dicotomização iterativa*** significa ***dividir-se repetidamente os atributos em duas ou mais classes*** a cada iteração (ou passo).
- O ***método ID3*** é uma abordagem que ***não garante*** a obtenção da ***menor árvore possível***, mas busca obter ***árvores apropriadas num intervalo de tempo relativamente curto***.

O processo de indução de uma árvore de decisão

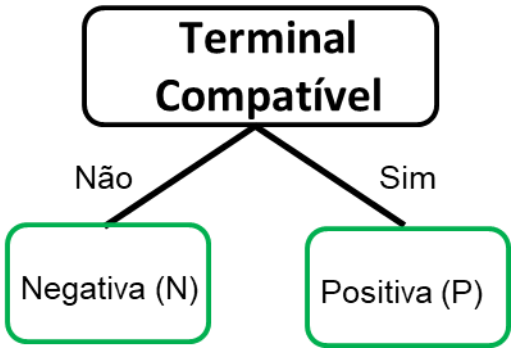
- Ele usa uma ***estratégia gananciosa top-down*.**
- Ou seja, a árvore é ***criada de cima para baixo*** e um ***nó é escolhido*** selecionando-se o ***atributo que melhor divide o conjunto de dados naquele momento***.
- Mas como se decide qual é o melhor atributo?
- Qual é a métrica usada?
- O ***método ID3*** se baseia na ***teoria da informação*** para selecionar o melhor atributo de cada nó da árvore.

O processo de indução de uma árvore de decisão



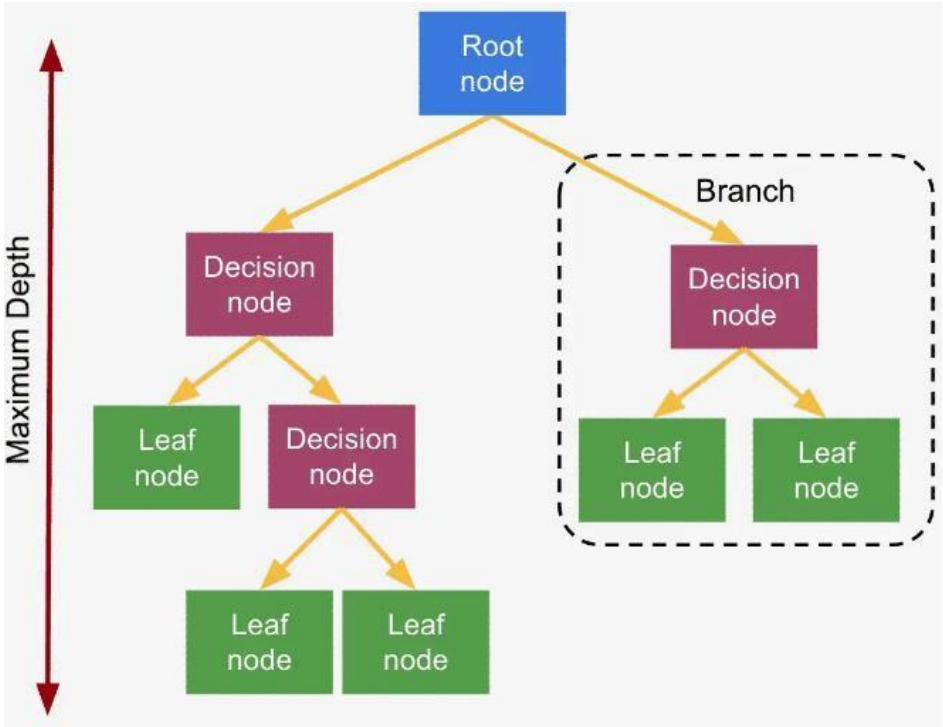
- A ideia do ***método ID3*** é escolher como ***nó*** o ***atributo que for o mais longe possível em dividir os exemplos***.
- Um ***atributo perfeito*** divide perfeitamente todos os exemplos em grupos (ou classes).
- Ou seja, é o atributo que consegue ***explicar perfeitamente o conjunto de dados***.
- Por exemplo, o atributo **Terminal compatível** divide as exemplos perfeitamente em duas classes.

O processo de indução de uma árvore de decisão



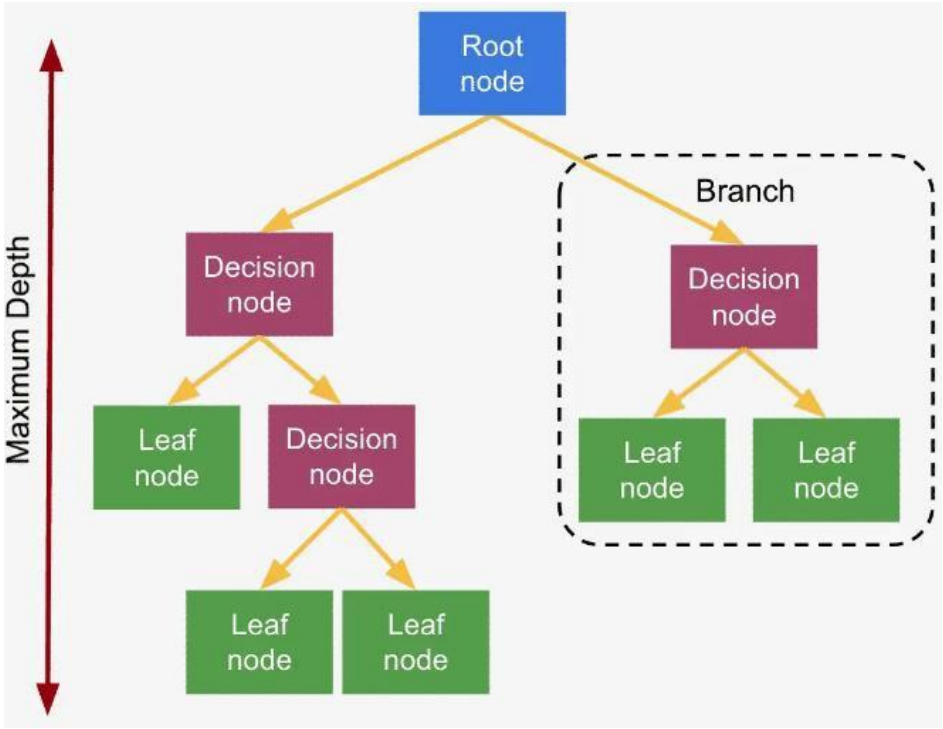
- Então, tudo o que precisamos é uma medida formal de ***atributo razoavelmente bom*** ou ***realmente inútil***.
- O ***método ID3*** utiliza a noção de ***ganho de informação***, o qual é ***definido em termos da entropia***, que é uma quantidade fundamental em ***teoria da informação***.
- A seguir, veremos alguns conceitos úteis para que possamos usar o ***método ID3*** para inferir árvores de decisão.

Ganho de informação



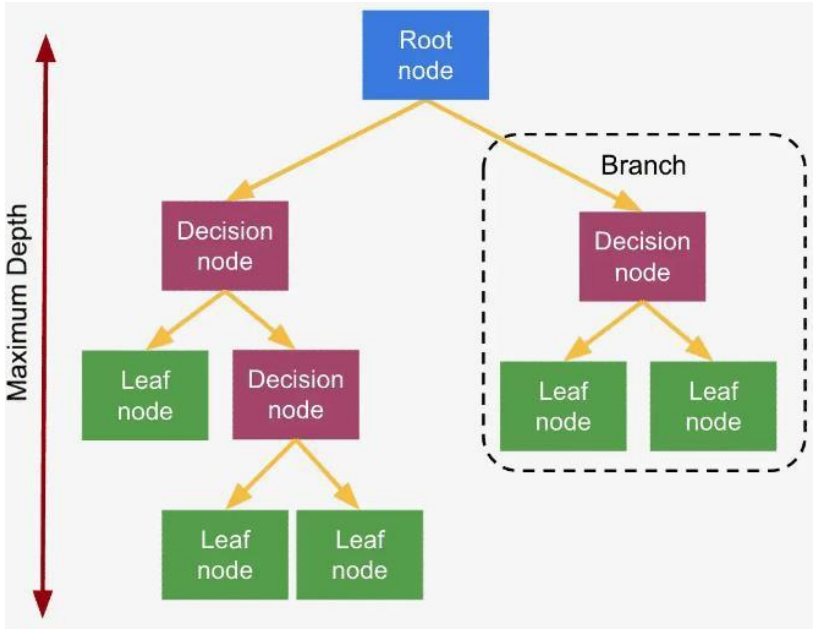
- É uma ***propriedade estatística*** que ***mede o qução bem um determinado atributo separa os exemplos*** de treinamento de acordo com suas classes.
- Portanto, construir uma ***árvore de decisão*** tem tudo a ver com encontrar, a cada momento (i.e., a cada nó), um ***atributo*** que retorne o maior ***ganho de informação***.

Entropia



- É uma medida da ***quantidade de incerteza ou aleatoriedade*** de uma variável aleatória (i.e., um conjunto de dados).
- Portanto, ***um ganho de informação*** corresponde a uma ***redução na entropia***.
- Quando ***ganhamos informação*** sobre o conjunto, a ***incerteza diminui***.
- O ganho é o quanto conseguimos explicar do conjunto com aquele atributo.

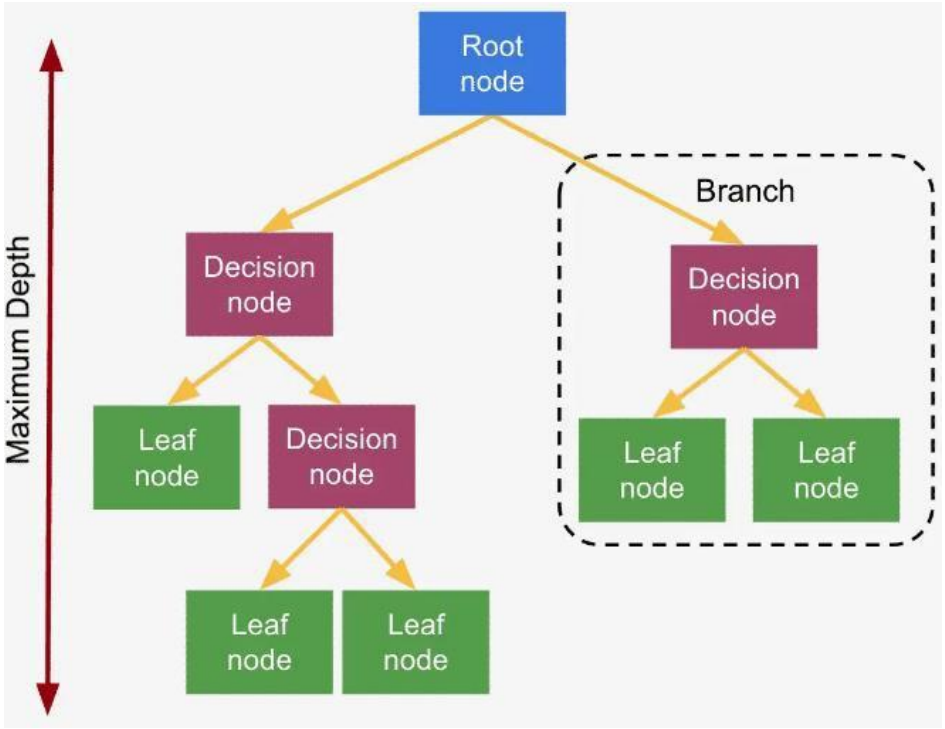
Entropia



- O ***ganho de informação*** nos dá a ***diferença entre a entropia antes e após a divisão do conjunto de dados*** com base nos valores de um determinado atributo.
- Assim, podemos escrever que o ***ganho de informação*** é dado por

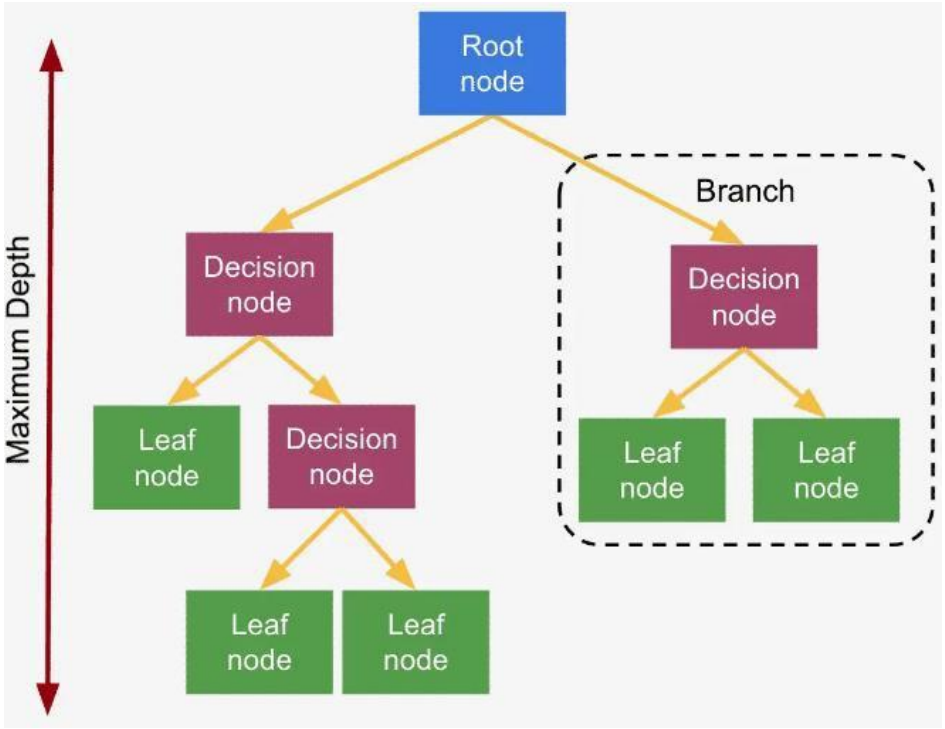
$$Gain = entropiaAntesDaDivisão \ - entropiaAposADivisão$$

Exemplo de entropia



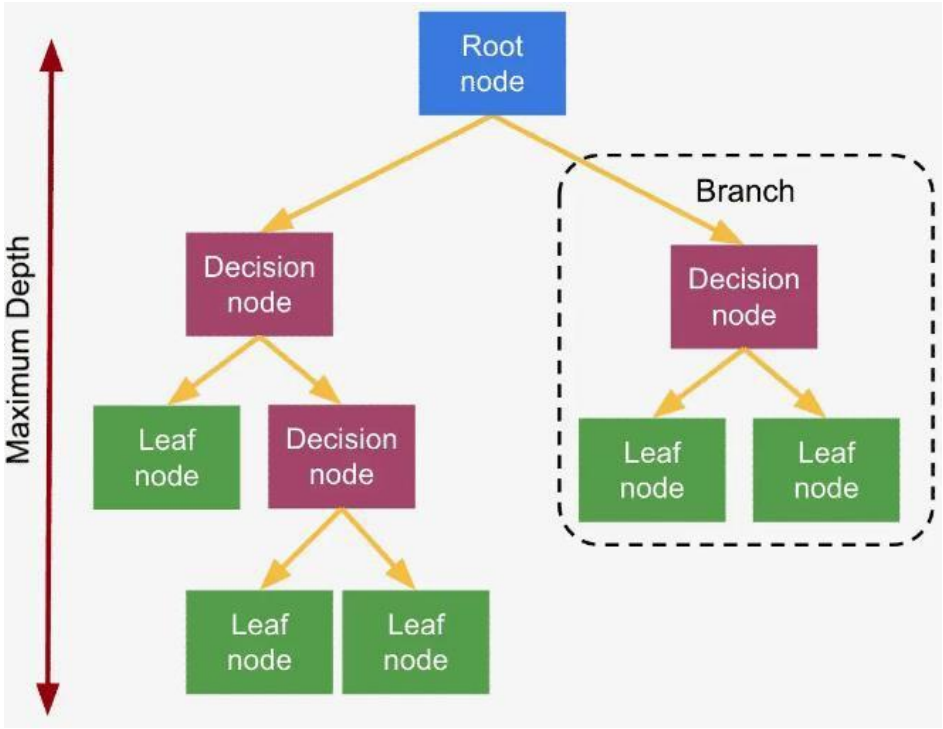
- Uma variável com apenas um único valor (e.g., o arremesso de uma moeda com ***cara*** em ambos os lados) não tem nenhuma ***incerteza*** associada
- Portanto, sua ***entropia é igual a zero***.
- Isso significa que ***não se ganha nenhuma informação nova ao se observar o valor***.

Exemplo de entropia



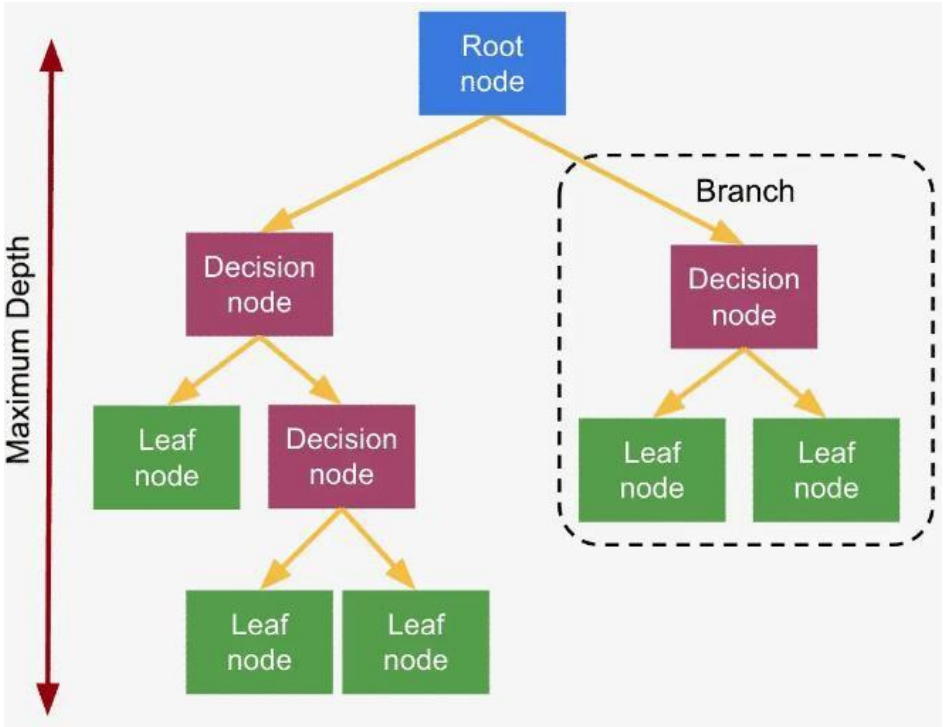
- Por outro lado, o resultado de se arremessar uma ***moeda honesta*** é igualmente provável de resultar em ***cara*** ou ***coroa***, os quais são associados aos valores 0 ou 1, respectivamente.
- Neste caso, esta variável tem ***1 bit de entropia***, significando que se necessita de 1 bit para representar os 2 possíveis resultados.

Exemplo de entropia



- Dessa forma, a variável aleatória que representa o resultado de se rolar um ***dado honesto de 4 lados***, ***tem 2 bits de entropia***, pois necessita-se de 2 bits para se representar os 4 possíveis valores.
- Agora imaginem um ***moeda desonesta*** que tenha uma probabilidade de resultar em ***cara*** em 99% dos arremessos.
- Nesse caso, a ***entropia*** deve ser um ***valor positivo muito próximo de zero***, pois a incerteza do resultado é muito baixa.

Cálculo da entropia



- Assim, a ***entropia*** de uma variável aleatória discreta, V, com valores v_i, onde cada um dos valores tem probabilidade $P(v_i)$, é definida como.

$$H(V) = -\sum_i P(v_i) \log_2 \left(P(v_i)\right)$$

Indução de uma árvore de decisão

- Retornando ao problema da indução de ***árvores de decisão*** nós temos que se um conjunto de treinamento, E, contém p exemplos pertencentes à classe positiva (*P*) e n exemplos pertencentes à classe negativa (*N*), então a ***entropia do objetivo*** (i.e., o rótulo) para todo o conjunto de treinamento é dada por

$$H(Goal) = B\left(\frac{p}{p+n}\right)$$

$$= -\left[\frac{p}{p+n}\log_2\left(\frac{p}{p+n}\right) + \left(1-\frac{p}{p+n}\right)\log_2\left(1-\frac{p}{p+n}\right)\right]$$

onde $B(q)$ é a ***entropia de uma variável booleana que é verdadeira com probabilidade igual a*** q, ou seja

$$B(q) = -[q\log_2(q) + (1-q)\log_2(1-q)].$$

Indução de uma árvore de decisão

- Um teste em um único atributo, x_k, pode nos dar ***toda ou apenas parte da entropia do objetivo***, $H(Goal)$.
- Nós podemos medir exatamente o ***quanto cada atributo contribui para a entropia do objetivo*** através do cálculo da ***entropia restante após o teste do atributo***.
- Um ***atributo*** x_k ***com*** d ***valores distintos divide o conjunto de treinamento*** E ***em*** d ***subconjuntos***: $E_1, \dots, E_d$.
- Cada subconjunto $E_i, i \in \{1, \dots d\}$, possui $p_i, i \in \{1, \dots d\}$, exemplos da classe positiva, *P*, e $n_i, i \in \{1, \dots d\}$, exemplos da classe negativa, *N*.

Indução de uma árvore de decisão

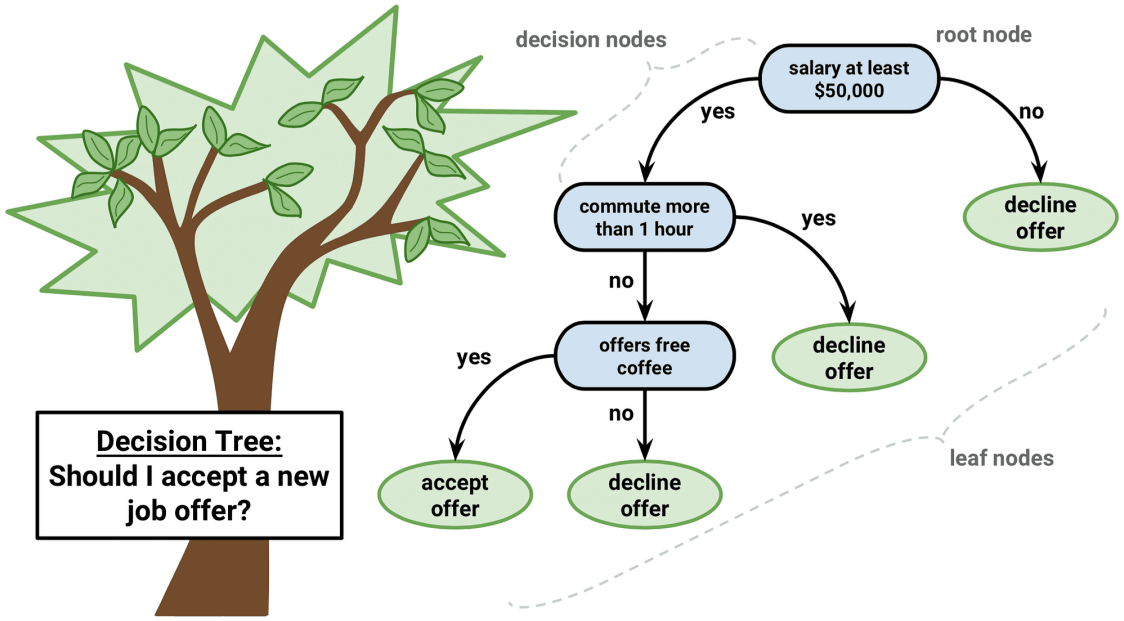
- Um exemplo escolhido aleatoriamente do conjunto de treinamento tem probabilidade igual a $(p_i + n_i)/(p + n)$ de pertencer ao i-ésimo subconjunto, E_i, do atributo x_k.
- Assim, a ***entropia restante*** após o teste do atributo x_k é dada por

$$Remainder(x_k) = \sum_{i=1}^{d} \frac{p_i + n_i}{p + n} B\left(\frac{p_i}{p_i + n_i}\right)$$

- O ***ganho de informação*** com o atributo x_k é a ***redução na entropia do objetivo***, que é dado por

$$Gain(x_k) = B\left(\frac{p}{p + n}\right) - Remainder(x_k) \geq 0.$$

Método ID3



- A ideia por trás do ***método ID3*** é encontrar o ***atributo x_k que maximiza o ganho de informação*** e, então, usar o procedimento ***recursivamente com os demais atributos***.
- Ou seja, escolhe-se o atributo que gera a primeira ramificação e, então, se repete o processo usando os demais atributos para construir o restante da árvore.

Sequência de passos do método ID3

a) Cálculo da ***entropia do objetivo*** para o (sub)conjunto de treinamento ***corrente***.
   - **OBS**.: o (sub)conjunto é alterado a cada nova iteração do método de acordo com o(s) atributo(s) sendo testado(s).

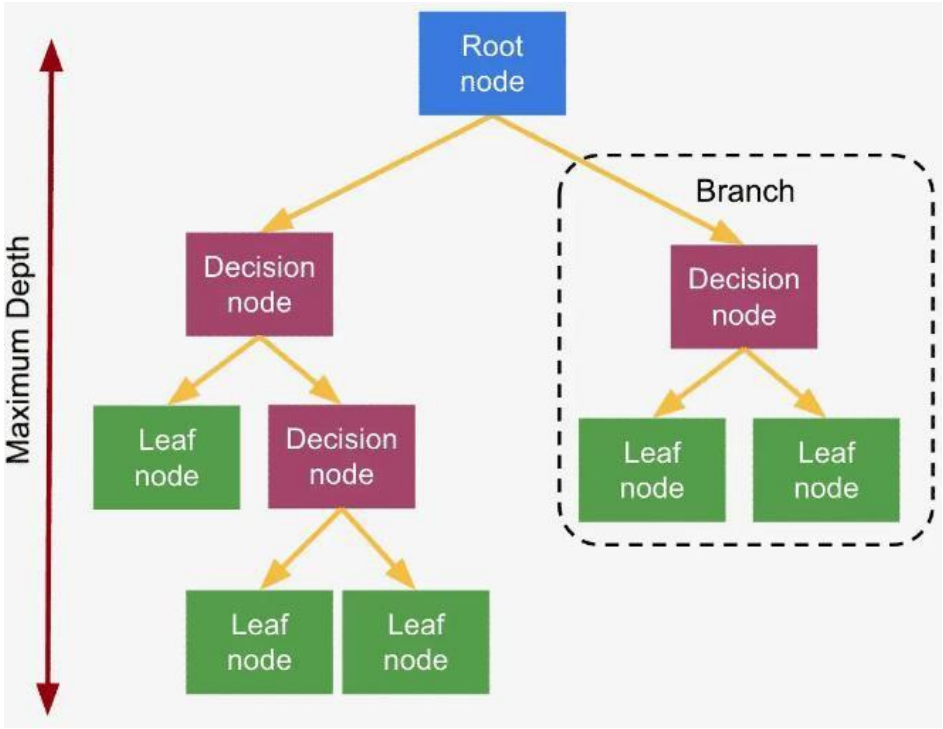
b) Cálculo do ***ganho de informação*** de cada atributo $x_k, k = 1, \dots, K$ do conjunto de treinamento, E.

c) Criação de um nó com o atributo que maximizou o ***ganho de informação***.

d) ***Particionamento do (sub)conjunto em subconjuntos*** usando o atributo x_k para o qual o ***ganho de informação*** resultante após a divisão é maximizado.

e) Repetir os itens a) até d) em ***subconjuntos de treinamento*** usando os atributos restantes. Essa sequência ***continua*** ***até que a árvore classifique perfeitamente todos os exemplos*** ***de treinamento*** ou ***até que todos os atributos tenham sido utilizados***.

Sequência de passos do método ID3

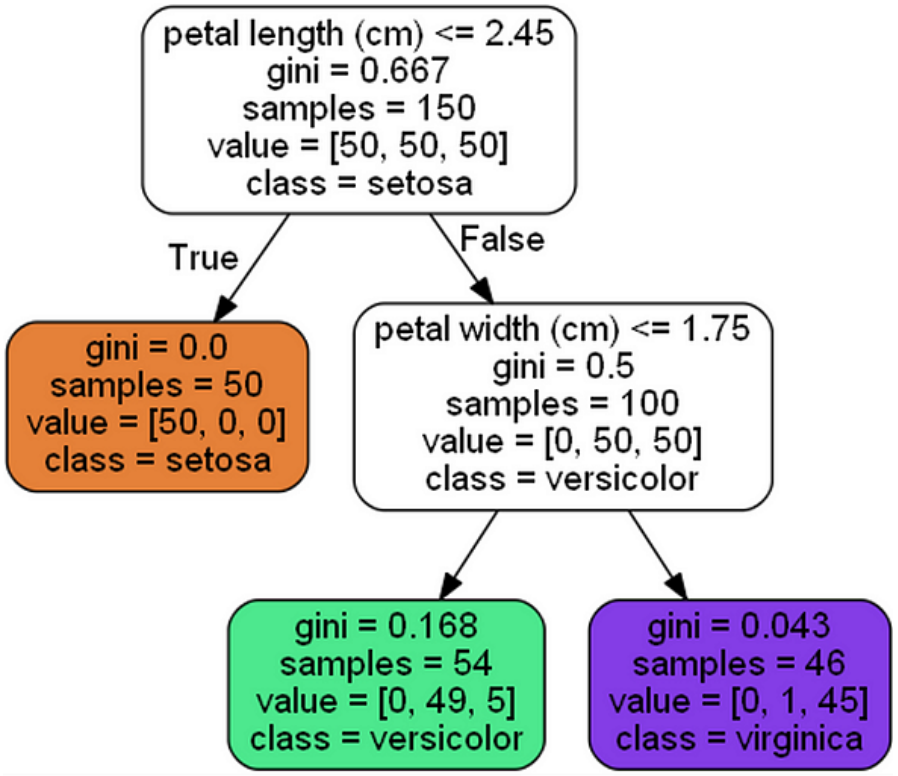


- O ***ID3*** segue a regra: um ***ramo*** com uma ***entropia igual a zero*** é uma ***folha*** e um ***ramo*** com ***entropia maior do que zero precisa de partição adicional***.
- O **método ID3** será exemplificado através do exemplo apresentado em breve.

Características do método ID3

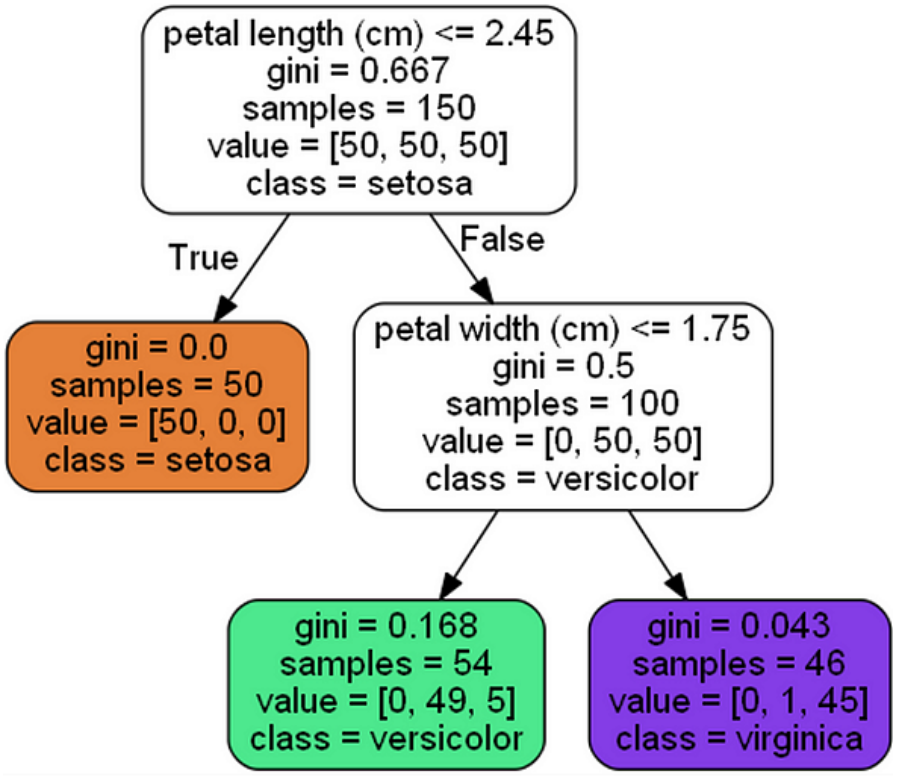
- Por usar uma abordagem baseada em uma ***heurística gananciosa***, o ID3 ***não garante uma solução ideal***.
- Pode sobreajustar aos dados de treinamento
  - Para evitar o sobreajuste, árvores de decisão menores devem ser preferidas ao invés das maiores.
- O método ID3 geralmente produz árvores pequenas, ***mas nem sempre*** produz ***a menor árvore possível***.
- É mais ***difícil de usar com dados contínuos***.
- Se os valores de um atributo forem contínuos, haverá muito mais pontos para se dividir os dados com esse atributo, e a busca pelo melhor valor a ser dividido pode se tornar demorada.

Observações



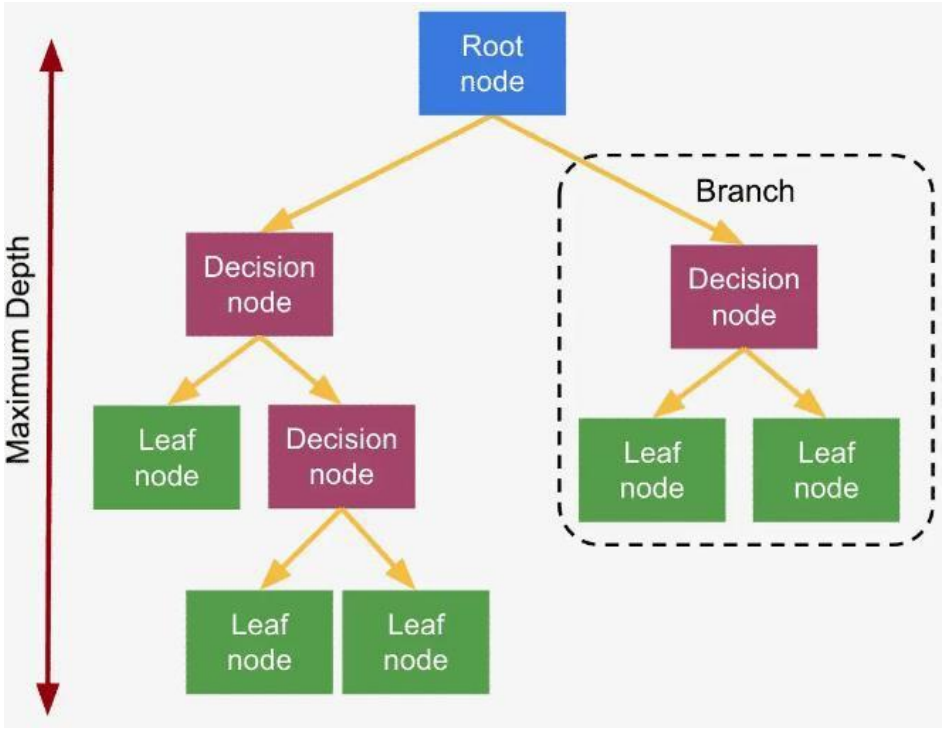
- Além do ***ganho de informação***, existem outras métricas que podem ser usadas para indução.
- Uma possibilidade é usar uma ***métrica de impureza***, como o ***índice de Gini***.
  - Usado no método CART do SciKit-Learn.
- Mede o quão bagunçado (i.e., impuro) é um conjunto de dados.
  - Valor 1: ***conjunto puro***, todas as amostras pertencem a uma mesma classe.
  - Valor 0: conjunto totalmente impuro, as amostras pertencem a classes diferentes.

Observações



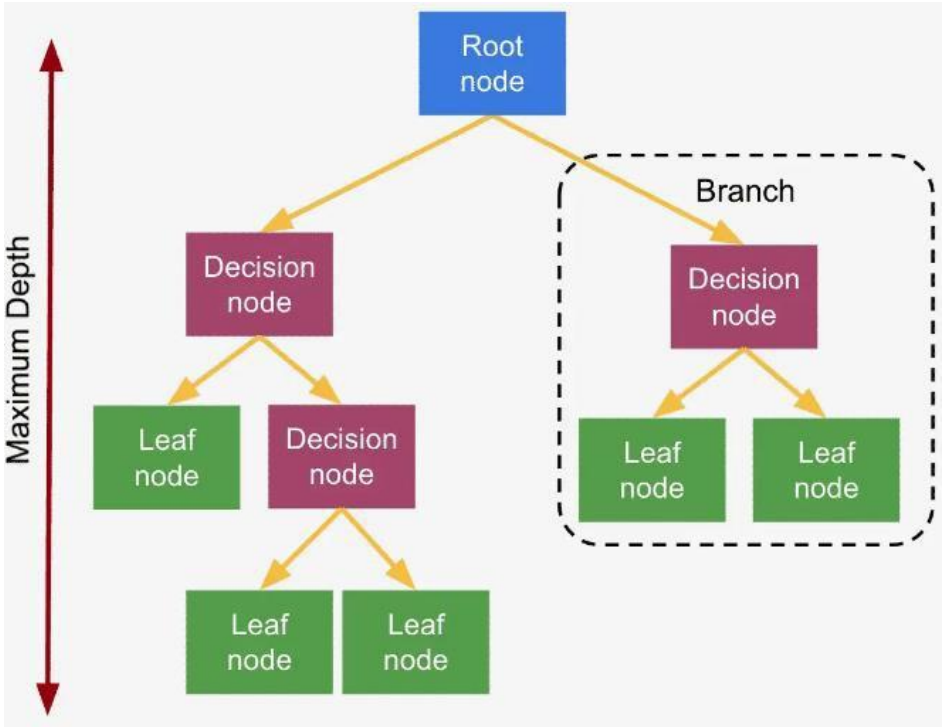
- Outro ponto importante é, se for o caso, deve-se buscar metodologias para se lidar com atributos faltantes.
- Existem várias soluções, como por exemplo:
  - Remover o exemplo.
  - Atribuir ao atributo a média de seus valores.

Observações



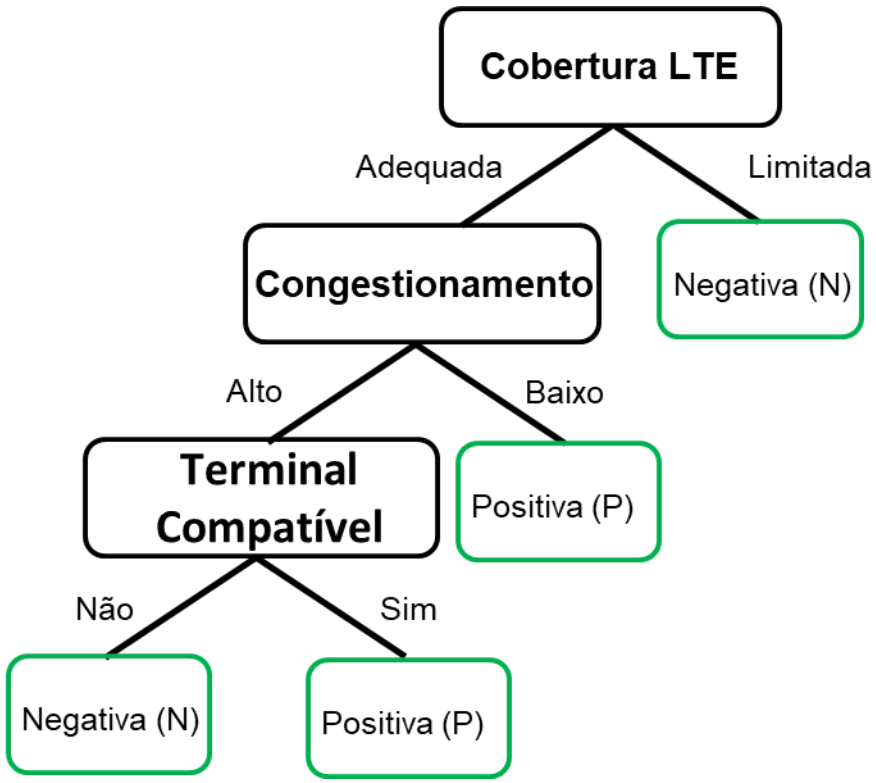
- O conjunto de treinamento é a base para definirmos a ***árvore de decisão***.
- Um conjunto que contenha inconsistências, como, por exemplo, ***dois exemplos com os mesmos valores de atributos, porém classes diferentes***, precisará ser reconsiderado, pois os atributos atuais podem não ser suficientes, por exemplo, ***precisando de mais atributos***.

Observações



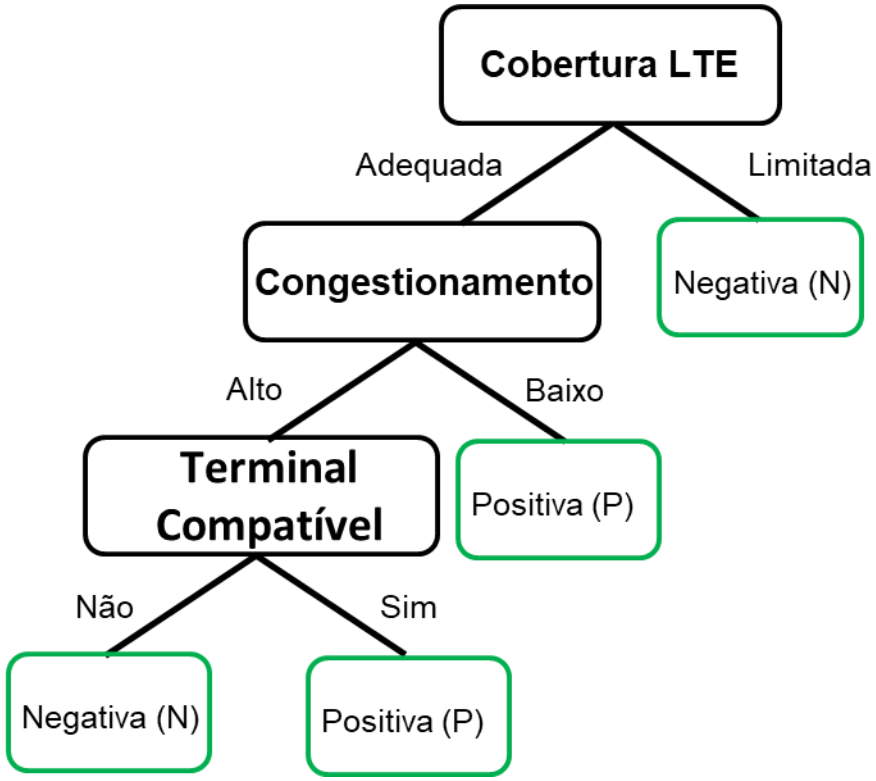
- Um problema muito comum das ***árvores de decisão***, especialmente quando se tem um número muito grande de atributos, é o ***sobreajuste (alta variância)***.
- Existem duas formas para se minimizar este problema
  - Podar as árvores de decisão (***tree prunning***).
  - Ou utilizar ***florestas aleatórias***.

Exemplo de indução de uma árvore de decisão com o método ID3



- Vamos construir uma árvore de decisão para ***predizer se jogadores irão ou não praticar um determinado esporte*** baseado em algumas ***condições meteorológicas***.
- Vamos considerar um conjunto de dados da forma$(\boldsymbol{x}_i, d_i)$, onde $\boldsymbol{x}_i$ é um vetor de atributos e d_i é um rótulo correspondente ao vetor de atributos.
- Nesse conjunto, cada entrada diz respeito à condição meteorológica de um dia e se os jogadores jogaram ou não.

Exemplo de indução de uma árvore de decisão com o método ID3



- Existem ***três*** atributos ***categóricos***:
  - **Cobertura LTE**: {Adequada, Limitada}
  - **Congestionamento**: {Alto, Baixo}
  - **Terminal Compatível**: {Sim, Não}
- Os rótulos são dois (problema binário): ***positivo*** (*P*), i.e., Completar a chamada, e ***negativo*** (*N*), i.e., Não completar a chamada.
- Um exemplo de condição de chamada de um determinado registro poderia ser descrito por:

  {Adequada, Baixo, Sim}

Indução de uma árvore de decisão com o método ID3

- O conjunto de treinamento do exemplo é dado pela tabela abaixo.

Registro	Atributos			Classe
	Cobertura LTE	Congestionamento	Terminal compatível	
1	Adequada	Baixo	Sim	P
2	Adequada	Baixo	Não	P
3	Adequada	Alto	Sim	P
4	Adequada	Alto	Não	N
5	Limitada	Baixo	Sim	N
6	Limitada	Baixo	Não	N
7	Limitada	Alto	Sim	N
8	Limitada	Alto	Não	N

planilha

Indução de uma árvore de decisão com o método ID3

- A ***entropia do objetivo***, i.e., y, para todo o conjunto de treinamento é

$$H(y) = -\left[\frac{3}{8}\log_2\left(\frac{3}{8}\right) + \left(1-\frac{3}{8}\right)\log_2\left(1-\frac{3}{8}\right)\right] = 0{,}9544$$

- Encontrando o nó raiz: o ***ganho de informação*** de cada atributo é calculado como

		Chamada completada?		
		P	N	
Cobertura LTE	Adequada	3	1	4
	Limitada	0	4	4
				8

		Chamada completada?		
		P	N	
Congestionamento	Baixo	2	2	4
	Alto	1	3	4
				8

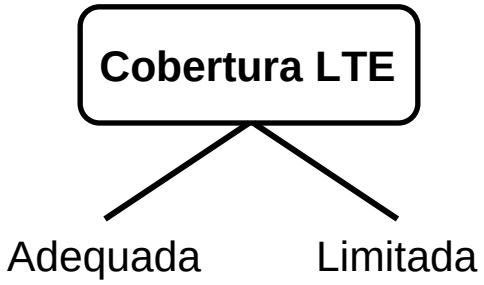
		Chamada completada?		
		P	N	
Terminal compatível	Sim	2	2	4
	Não	1	3	4
				8

$$Gain(\textbf{Cobertura LTE}) = 0{,}9544 - \left[\frac{4}{8}B\left(\frac{3}{4}\right) + \frac{4}{8}B\left(\frac{0}{4}\right)\right] = 0{,}9544 - 0{,}4056 = 0{,}5488$$

$$Gain(\textbf{Congestionamento}) = 0{,}9544 - \left[\frac{4}{8}B\left(\frac{2}{4}\right) + \frac{4}{8}B\left(\frac{1}{4}\right)\right] = 0{,}9544 - 0{,}9056 = 0{,}0488$$

$$Gain(\textbf{Terminal Compatível}) = 0{,}9544 - \left[\frac{4}{8}B\left(\frac{2}{4}\right) + \frac{4}{8}B\left(\frac{1}{4}\right)\right] = 0{,}9544 - 0{,}9056 = 0{,}0488$$

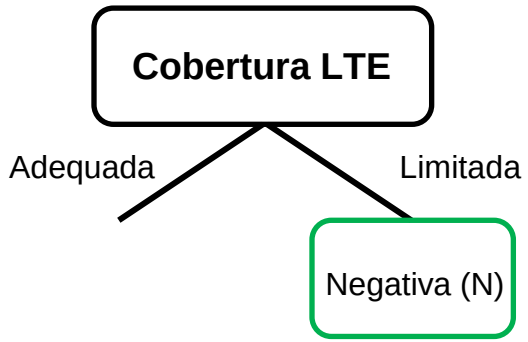
O ***ganho de informação*** é maximizado com o atributo ***Cobertura LTE***, que é, portanto, escolhido como o nó raíz da árvore.



Indução de uma árvore de decisão com o método ID3

- Agora, criamos ***subconjuntos para cada um dos valores*** do atributo ***Cobertura LTE*** e refazemos os cálculos do ***ganho de informação*** para cada um deles.
- Quando ***Cobertura LTE = Limitada*** , o subconjunto abaixo mostra que os valores dos outros atributos não importam, sendo a classe escolhida sempre a ***Negativa*** (*N*), ou seja, a ***decisão será sempre pela classe "Negativa (N)" se a cobertura for limitada***.
- A ***entropia nessa caso é igual a zero*** (pois não há incerteza), indicando uma ***folha*** da árvore.
- Portanto, encontramos a folha deste ramo.

Registro	Atributos			Classe
	Cobertura LTE	Congestionamento	Terminal Compatível	
5	Limitada	Baixo	Sim	N
6	Limitada	Baixo	Não	N
7	Limitada	Alto	Sim	N
8	Limitada	Alto	Não	N



Indução de uma árvore de decisão com o método ID3

- Quando ***Cobertura LTE = Adequada***

Registro	Atributos			Classe
	Cobertura LTE	Congestionamento	Terminal compatível	
1	Adequada	Baixo	Sim	P
2	Adequada	Baixo	Não	P
3	Adequada	Alto	Sim	P
4	Adequada	Alto	Não	N

$$H(y) = -\left[\frac{3}{4}\log_2\left(\frac{3}{4}\right) + \left(\frac{1}{4}\right)\log_2\left(\frac{1}{4}\right)\right] = 0{,}8113$$

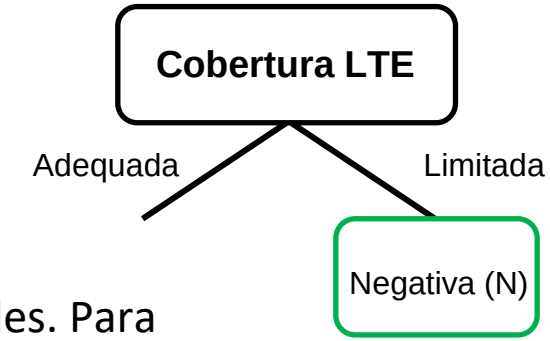
		Chamada completada?		
		P	N	
Congestionamento	Baixo	2	0	2
	Alto	1	1	2
				4

		Chamada completada?		
		P	N	
Terminal Compatível	Sim	2	0	2
	Não	1	1	2
				4

Entropia do objetivo para o subconjunto **Cobertura LTE = Adequada** : $H(y \mid \text{Cobertura LTE}=\text{Adequada}) = 0{,}8113$

$$Gain(\textbf{Congestionamento}) = 0{,}8113 - \left[\frac{2}{4}B\left(\frac{2}{2}\right) + \frac{2}{4}B\left(\frac{1}{2}\right)\right] = 0{,}8113 - 0{,}5 = 0{,}3113$$

$$Gain(\textbf{Terminal Compatível}) = 0{,}8113 - \left[\frac{2}{4}B\left(\frac{2}{2}\right) + \frac{2}{4}B\left(\frac{1}{2}\right)\right] = 0{,}8113 - 0{,}5 = 0{,}3113$$

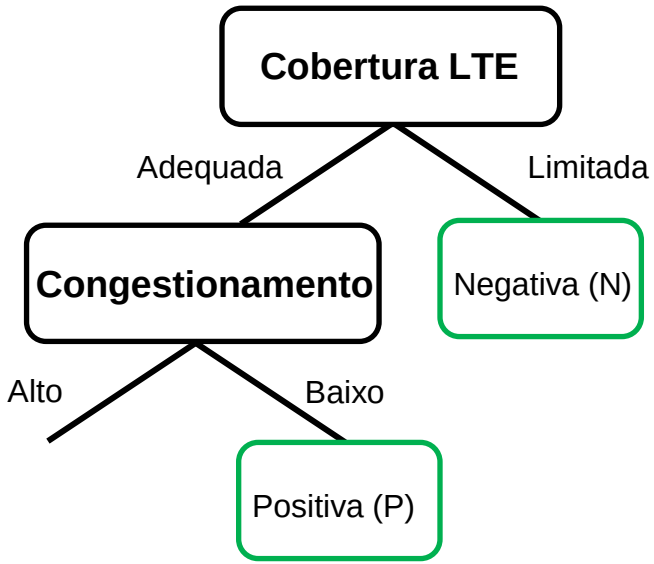


- Há um empate: os dois atributos têm o mesmo ganho. O ID3 pode escolher qualquer um deles. Para continuar a resolução, escolherei **Congestionamento**.

Indução de uma árvore de decisão com o método ID3

- Se analisarmos o subconjunto onde ***Cobertura LTE = Adequada*** e ***Congestionamento = Baixo***, percebemos que a decisão será sempre pela classe ***Positiva*** (*P*).
- A entropia H(y|Cobertura LTE = Adequada, Congestionamento = Baixo) = 0.

Registro	Atributos			Classe
	Cobertura LTE	Congestionamento	Terminal Compatível	
1	Adequada	Baixo	Sim	P
2	Adequada	Baixo	Não	P



Indução de uma árvore de decisão com o método ID3

- Se analisarmos o subconjunto onde ***Cobertura LTE = Adequada*** e ***Congestionamento = Alto***, percebemos que há uma classe positivia e uma negativa, precisamos dividir novamente

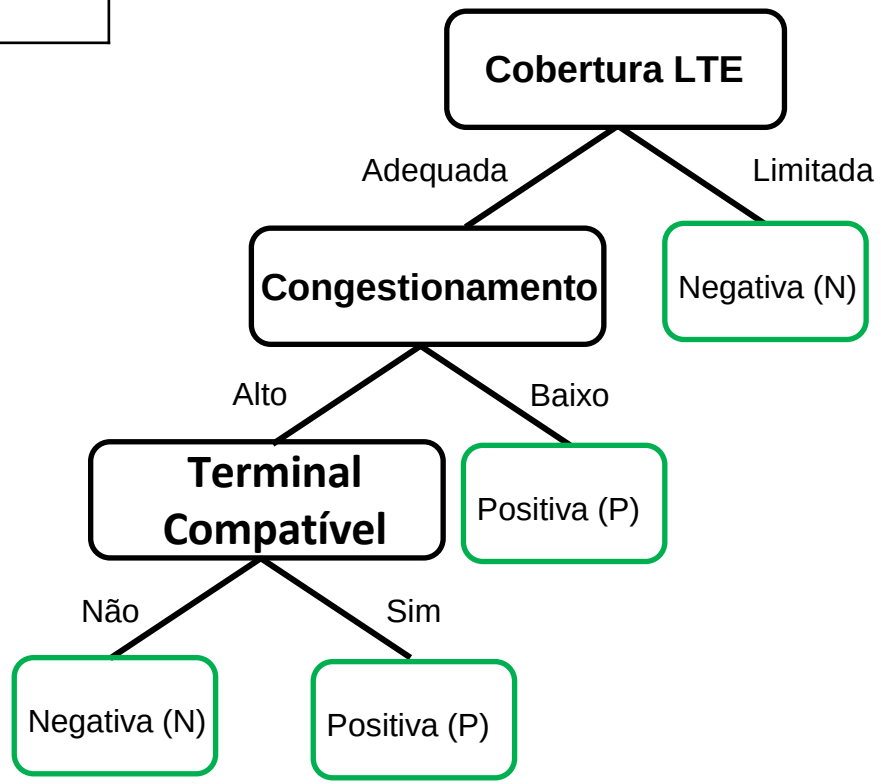
Registro	Atributos			Classe
	Cobertura LTE	Congestionamento	Terminal Compatível	
3	Adequada	Alto	Sim	P
4	Adequada	Alto	Não	N

$$H(y) = -\left[\frac{1}{2}\log_2\left(\frac{1}{2}\right) + \left(\frac{1}{2}\right)\log_2\left(\frac{1}{2}\right)\right] = 1$$

		Chamada completada?		
		P	N	
Terminal Compatível	Sim	1	0	1
	Não	0	1	1
				2

$$Gain(\textbf{Terminal Compatível}) = 1 - \left[\frac{1}{2}B\left(\frac{1}{1}\right) + \frac{1}{2}B\left(\frac{1}{1}\right)\right] = 1 - 0 = 1$$

- Dividir por compatibilidade separa os exemplos em grupos puros:



Considerações sobre as árvores de decisão

- Embora as ***árvores de decisão*** sejam poderosos algoritmos de ***classificação***, elas podem apresentar um ***longo tempo de treinamento, principalmente quando os atributos são contínuos***.
- Árvores de decisão ***precisam de muito pouco pré-processamento dos dados***. Em particular, elas ***não necessitam de escalonamento dos atributos***, mas ***valores faltantes devem ser tratados de alguma forma***.
- Em casos onde as classes são separadas por ***fronteiras de decisão não-lineares***, as árvores de decisão apresentam um ***desempenho de classificação superior*** ao apresentado por ***classificadores com fronteiras de decisão formadas por hiperplanos***.
  - ***Exemplo***: DTTwoConcentricClassesClassification.ipynb

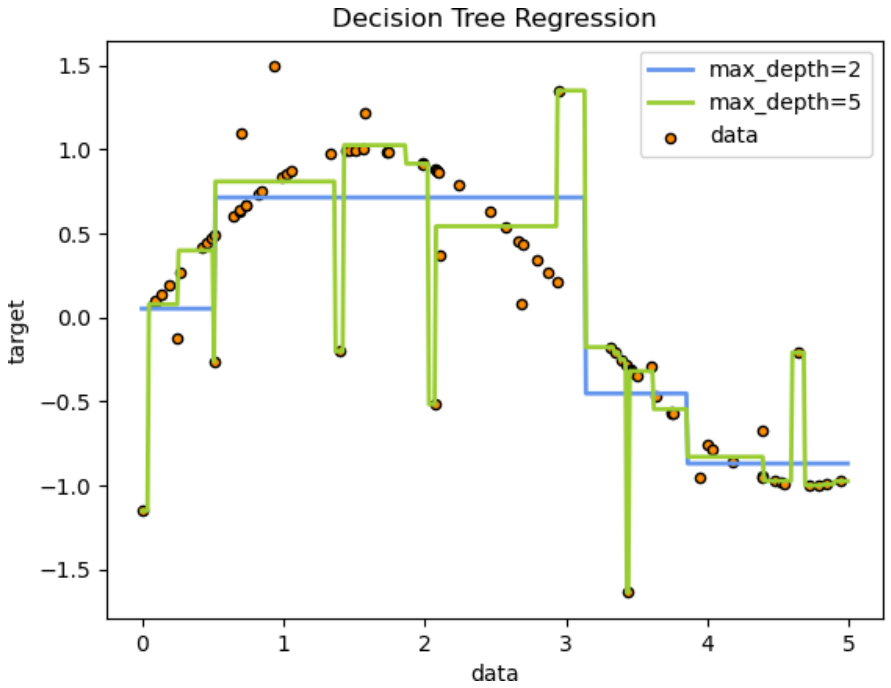
Considerações sobre as árvores de decisão

- Quando as ***classes não são bem separadas*** (i.e., se elas se sobrepõem), ***as árvores são suscetíveis a sobreajustar*** ao conjunto de treinamento, de modo que a ***fronteira de decisão linear*** de ***classificadores lineares*** separa melhor as classes, apresentando melhor desempenho de ***classificação***.
- Para evitar ***sobreajuste***, existem duas maneiras:
    1. Limitamos sua profundidade e/ou o número mínimo de amostras necessárias em um nó folha.
    2. Geramos primeiro uma árvore completa e, em seguida, eliminamos alguns ramos (i.e., podamos a árvore).
- ***Exemplo***: DTTwoOverlappingClassesClassification.ipynb

Considerações sobre as árvores de decisão

- O ***principal problema*** das árvores de decisão é que elas são ***muito sensíveis a pequenas variações nos dados de treinamento*** (e.g., rotação).
- Árvores de decisão criam ***fronteiras de decisão compostas por trechos perpendiculares aos eixos***, o que as torna ***sensíveis à rotação do conjunto de treinamento***.
- ***Exemplo***: DTSensitivityToTrainingSetRotation.ipynb
- Uma maneira para ***minimizar*** esse problema da sensibilidade à rotação é usar a técnica conhecida como ***Análise de Componentes Principais (PCA)***, que rotaciona e dimensiona linearmente a matriz de atributos.

Considerações sobre as árvores de decisão



- ***Árvores de decisão*** também podem ser utilizadas para ***regressão***.
  - As ***árvores de decisão*** também tendem a se ***sobreajustar*** ao lidar com tarefas de ***regressão***.
  - ***Exemplo***: DTNoisyQuadraticDatasetRegression.ipynb
- Predições feitas por ***árvores de decisão*** ***não são suaves nem contínuas***, mas ***aproximações constantes por partes/trechos***, conforme visto na figura ao lado.
- O valor previsto para cada trecho é sempre o ***valor médio*** dos exemplos ***nesse trecho***.

Avisos

- Nossa próxima aula será um estudo dirigido sobre ***florestas aleatórias*** (Lista #8) e ***k-Means*** (Lista #9).
- A presença será validada através da entrega das listas.
- Material se encontra no github.



Material das aulas

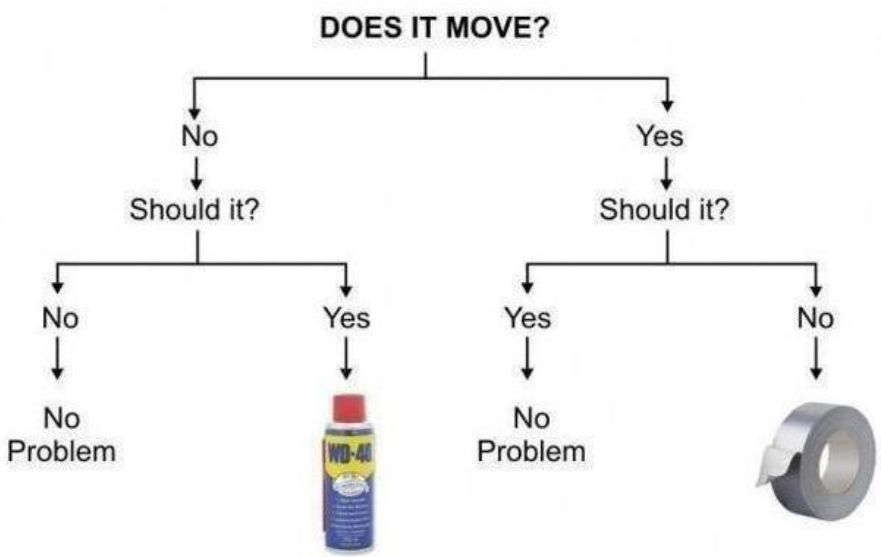
O material das aulas pode ser encontrado na pasta **slides** e pode ser acessado através dos links abaixo.

1. Introdução
2. Regressão Linear
3. Regressão Não-Linear
4. Classificação
5. kNN
6. Decision Trees
7. Ensemble Learning e Random Forests
8. k-Means

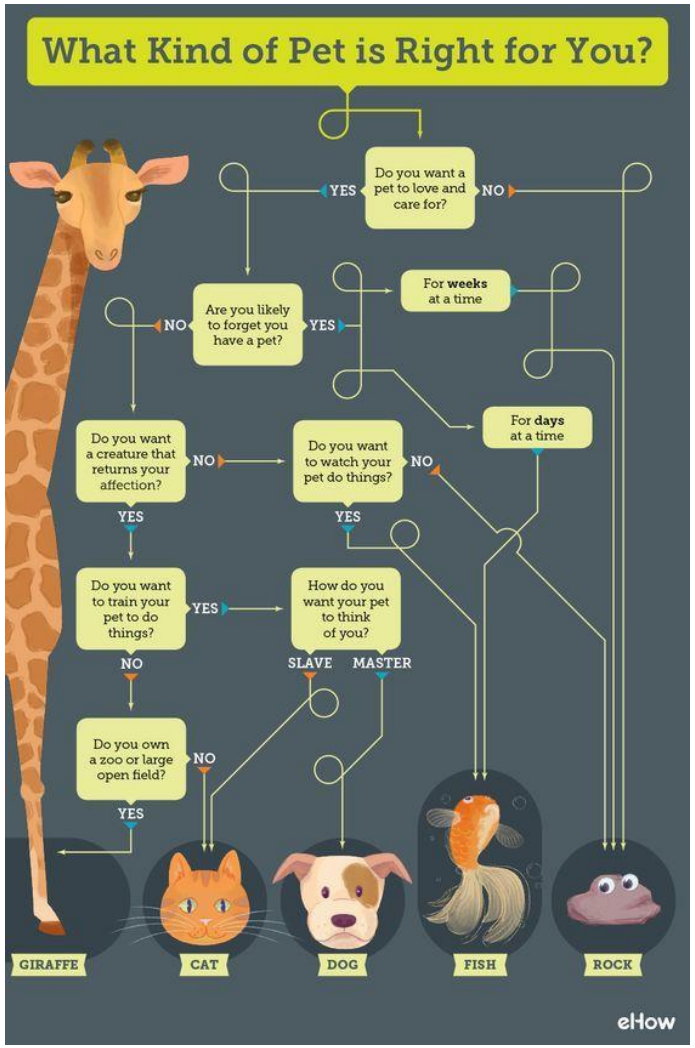
Considerações sobre as árvores de decisão

- Se não for restringida, a ***árvore de decisão*** se adaptará aos dados de treinamento, ajustando-se muito bem e, provavelmente, se ***sobreajustando*** a eles.
- Para evitar o ***sobreajuste*** do modelo, nós precisamos ***restringir a liberdade de crescer*** da árvore de decisão durante seu treinamento.
  - Essa restrição pode ser visto como uma forma de ***regularização.***
- No Scikit-Learn, a regularização pode ser controlada pelos hiperparâmetros: ***max_depth***, ***min_samples_split***, ***min_samples_leaf***, ***min_weight_fraction_leaf***, ***max_leaf_nodes*** e ***max_features***.
- ***Exemplo***: DTRegularizationHyperparameters.ipynb

Obrigado!


DOES IT MOVE?
No
Yes
Should it?
Should it?
No
Yes
Yes
No
No Problem
No Problem


MUST I EXERCISE?
DO I WANT TO GO FOR A JOG?
YES
NO
Did I get enough sleep?
Am I just being lazy?
YES
NO
YES
NO
Am I in sound condition?
Skip it. Do it tomorrow.
Get up. Go.
If you're not sick, go for it.
YES
NO
Rest today.
Do it.


What Kind of Pet is Right for You?
Do you want a pet to love and care for?
YES
NO
Are you likely to forget you have a pet?
NO
YES
For weeks at a time
For days at a time
Do you want a creature that returns your affection?
NO
YES
Do you want to watch your pet do things?
NO
YES
Do you want to train your pet to do things?
YES
NO
How do you want your pet to think of you?
SLAVE
MASTER
Do you own a zoo or large open field?
NO
YES
GIRAFFE
CAT
DOG
FISH
ROCK
eHow

Anexo I: Cálculo da entropia para mais de duas classes

Cálculo da entropia para mais de duas classes

- Veja a tabela ao lado com os exemplos de treinamento.
- Problema com três classes: 0, 1, e 2. Portanto, o cálculo da entropia terá três termos.
- A ***entropia*** do objetivo, i.e., y, para o conjunto de treinamento é

Atributos		**Rótulos**
x1	**x2**	**Classe (y)**
0	0	0
2	1	1
1	1	2
3	0	0

$$H(y) = -\left[\frac{2}{4}\log_2\left(\frac{2}{4}\right) + \left(\frac{1}{4}\right)\log_2\left(\frac{1}{4}\right) + \left(\frac{1}{4}\right)\log_2\left(\frac{1}{4}\right)\right] = 1.5$$

- Separando os atributos em tabelas separadas, temos

		Classes (y)			
		0	1	2	
x1	0	1	0	0	1
	1	0	0	1	1
	2	1	1	0	2
					4

		Classes (y)			
		0	1	2	
x2	0	2	0	0	2
	1	0	1	1	2
					4

- O ***ganho de informação*** de cada atributo é calculado como:

$$Gain(\boldsymbol{x1}) = H(y) - \left\{\frac{1}{4}H(x1 = 0) + \frac{1}{4}H(x1 = 1) + \frac{2}{4}H(x1 = 2)\right\}$$

$$Gain(\boldsymbol{x2}) = H(y) - \left\{\frac{2}{4}H(x2 = 0) + \frac{2}{4}H(x2 = 1)\right\}$$

Cálculo da entropia para mais de duas classes

Como exemplo do cálculo da entropia, vejamos como $H(x1 = 0)$ deve ser calculado.

$$H(x1 = 0) = -\sum_{i=0}^{2} p(y = i|x1 = 0)\log_2\big(p(y = i|x1 = 0)\big)$$

$$= -\big[p(y = 0|x1 = 0)\log_2\big(p(y = 0|x1 = 0)\big) + p(y = 1|x1 = 0)\log_2\big(p(y = 1|x1 = 0)\big) + p(y = 2|x1 = 0)\log_2(p(y = 2|x1 = 0)\big]$$

Assim, os ganhos de informação para $x1$ e $x2$ são calculados como

$$Gain(x1) = H(y) - \left\{\frac{1}{4}H(x1 = 0) + \frac{1}{4}H(x1 = 1) + \frac{2}{4}H(x1 = 2)\right\}$$

$$= H(y) - \left\{\frac{1}{4}\left[\frac{1}{1}\log_2\left(\frac{1}{1}\right)\right] + \frac{1}{4}\left[\frac{1}{1}\log_2\left(\frac{1}{1}\right)\right] + \frac{2}{4}\left[\frac{1}{2}\log_2\left(\frac{1}{2}\right) + \frac{1}{2}\log_2\left(\frac{1}{2}\right)\right]\right\}$$

$$Gain(x2) = H(y) - \left\{\frac{2}{4}H(x2 = 0) + \frac{1}{4}H(x2 = 1)\right\}$$

$$= H(y) - \left\{\frac{2}{4}\left[\frac{2}{2}\log_2\left(\frac{2}{2}\right)\right] + \frac{2}{4}\left[\frac{1}{2}\log_2\left(\frac{1}{2}\right) + \frac{1}{2}\log_2\left(\frac{1}{2}\right)\right]\right\}$$

Obs.:

- $H(0) = 0$
- $H(1) = 0$
- $0 * \log_2(0) = 0$

		Classes (y)			
		0	1	2	
x1	0	1	0	0	1
	1	0	0	1	1
	2	1	1	0	2
					4

		Classes (y)			
		0	1	2	
x2	0	2	0	0	2
	1	0	1	1	2
					4

Anexo II: Qual a entropia de 0?

Qual a entropia de 0?

- À primeira vista, pode parecer que $-x\log_2(x)$ é um valor indeterminado, pois resulta em $0 \times -\infty$. Porém, se fizermos uma pequena modificação na equação:

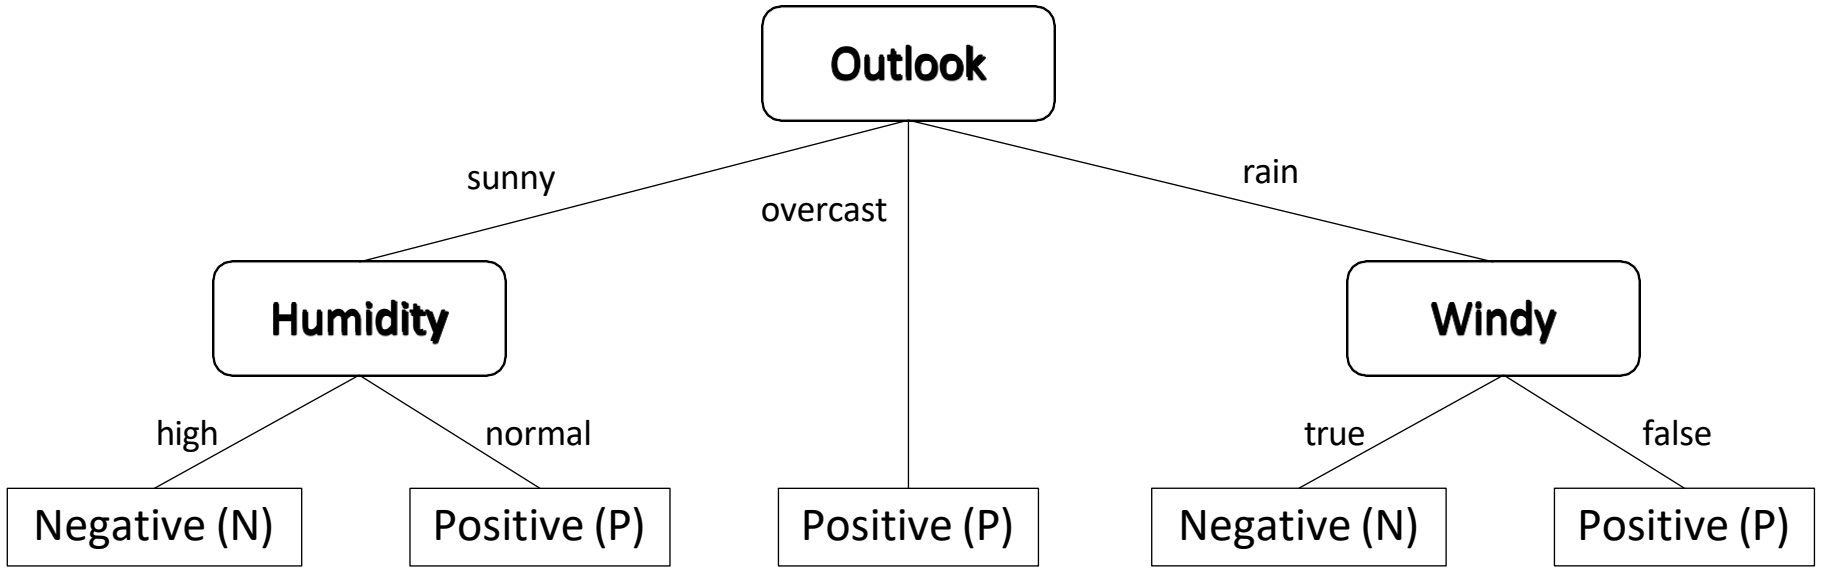
$$H(x) = -x\log_2(x) = -\frac{\log_2(x)}{\frac{1}{x}}$$

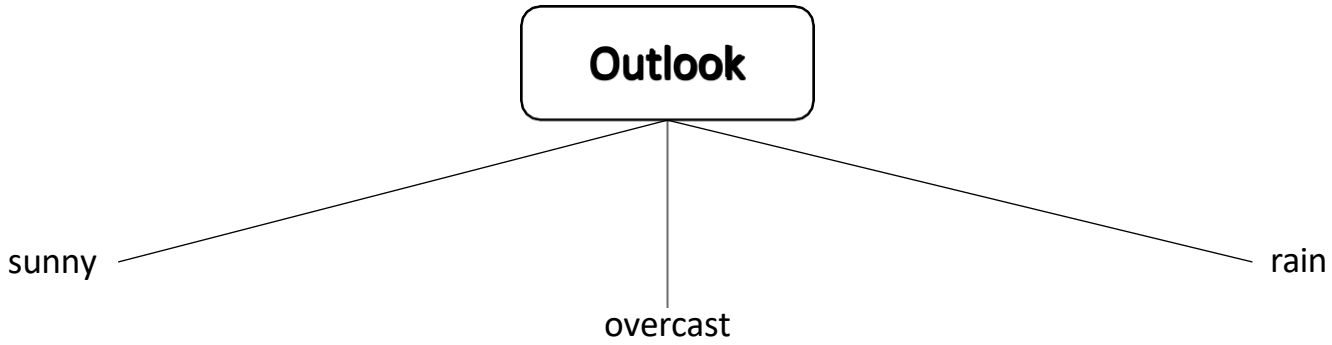
e, na sequência, aplicarmos a regra de L'Hôpital, conseguimos encontrar o valor quando x se aproxima de zero do lado positivo (0_+):

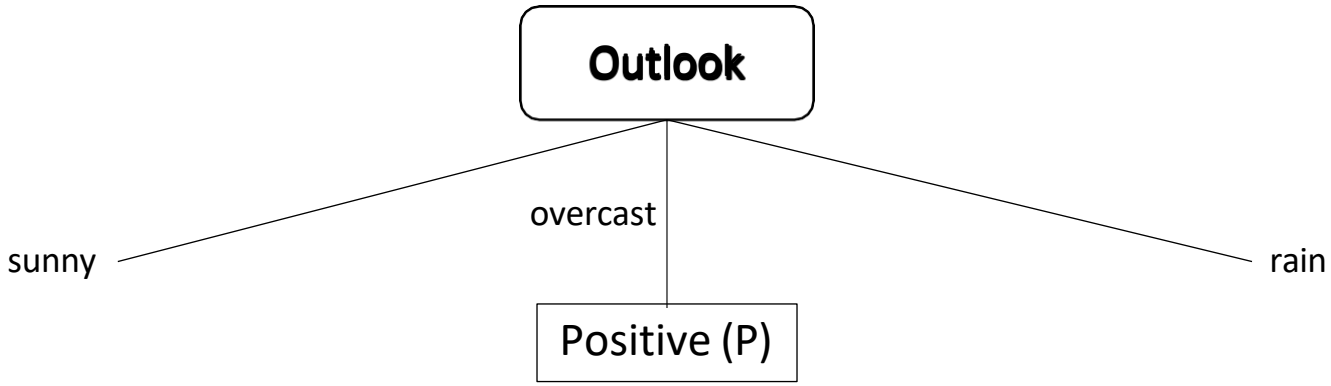
$$\lim_{x\to 0_+} H(x) = \lim_{x\to 0_+} \frac{\frac{1}{x\log_2(2)}}{-\frac{1}{x^2}} = \lim_{x\to 0_+} \frac{x}{\log_2(2)} = 0$$

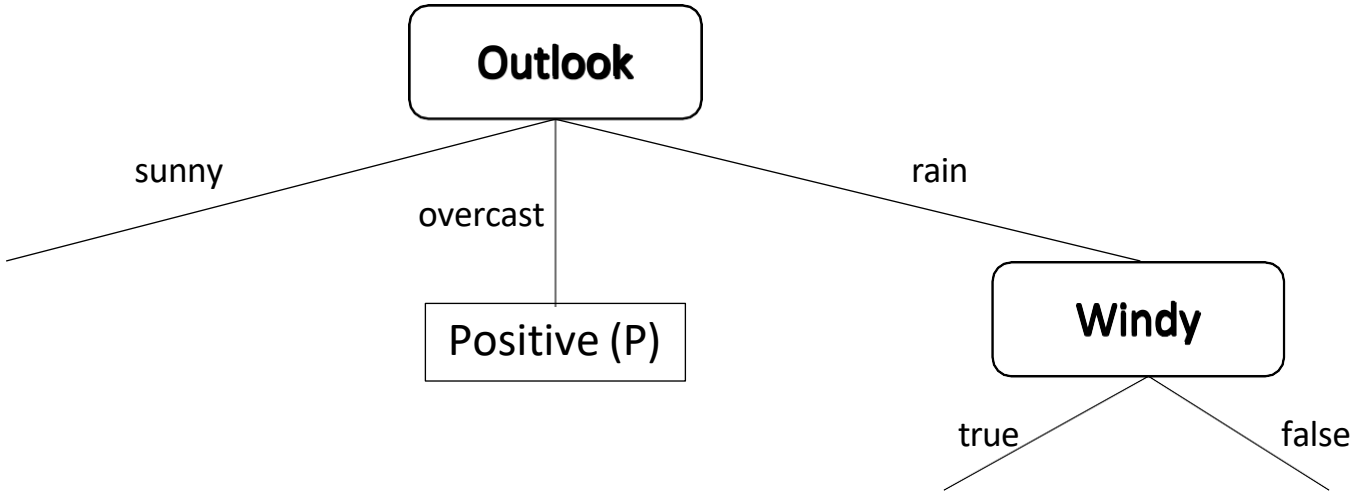
Assim, $H(x) = 0$.

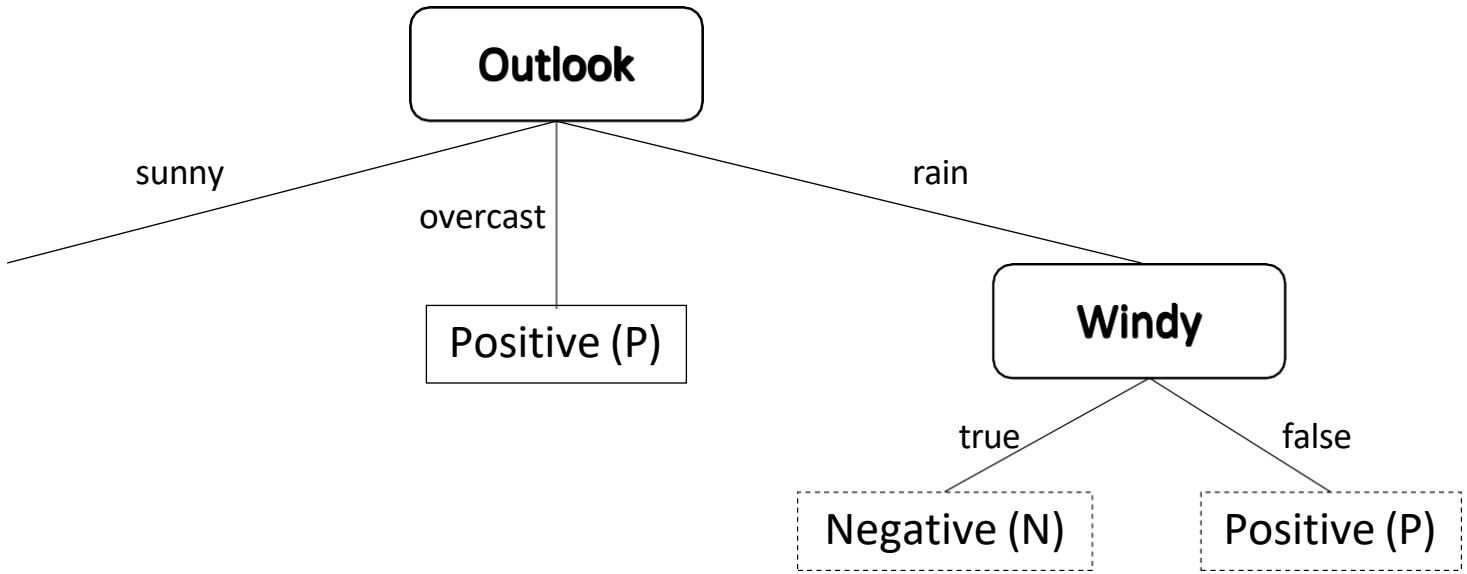
Figuras

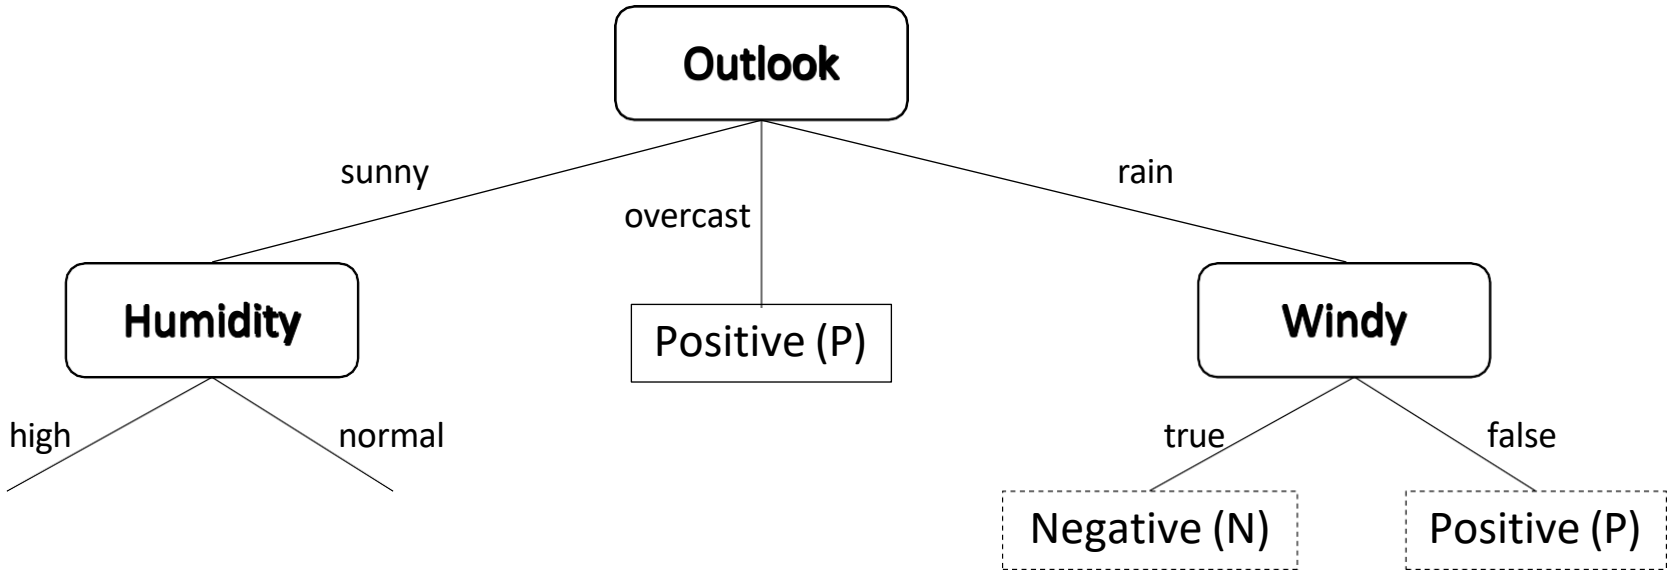

Outlook
sunny
overcast
rain
Humidity
Windy
high
normal
true
false
Negative (N)
Positive (P)
Positive (P)
Negative (N)
Positive (P)

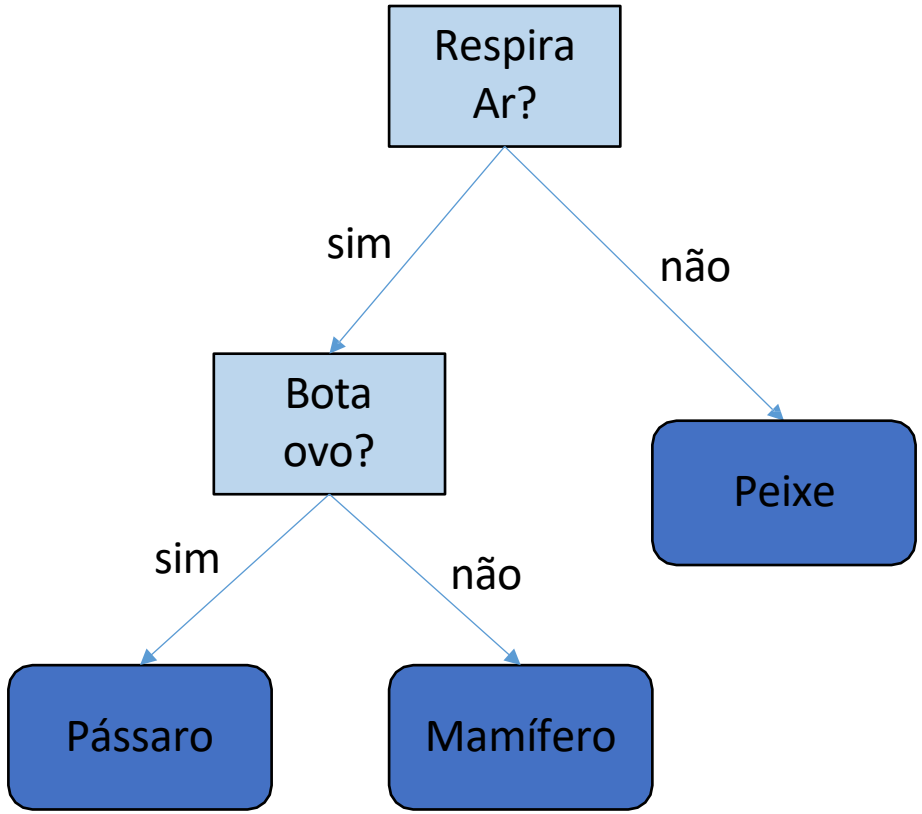

Outlook
sunny
overcast
rain


Outlook
sunny
overcast
rain
Positive (P)


Outlook
sunny
overcast
rain
Positive (P)
Windy
true
false


Outlook
sunny
overcast
rain
Positive (P)
Windy
true
false
Negative (N)
Positive (P)


Outlook
sunny
overcast
rain
Humidity
Positive (P)
Windy
high
normal
true
false
Negative (N)
Positive (P)


Respira
Ar?
sim
não
Bota
ovo?
Peixe
sim
não
Pássaro
Mamífero